INTELIGENCIA DE NEGOCIOS · PROYECTO FINAL

Solución de Inteligencia de Negocios: OEE en líneas de envasado

Diseño, implementación y despliegue contenerizado de una solución de BI de extremo a extremo sobre los registros de producción y paros de cuatro líneas de envasado

INTEGRANTE	Samuel Alvarez Becerra
REPOSITORIO	https://github.com/00Ssam00/taller-5-oee
FUENTE DE DATOS	Seguimiento Temperas y Vinilos Actividad.xlsm Procedimiento P-MTO-22 V1 (vigente desde el 14/05/2025)
MOTOR	PostgreSQL 17 · Grafana 11.6 · Power BI (PBIP/TMDL)

Contenido

1. Usuarios y preguntas de negocio
2. Diagnóstico de la fuente
3. Catálogo de indicadores
4. Modelo dimensional
5. Diccionario de datos
6. ETL, calidad de datos y conciliación
7. Arquitectura de la solución
8. Power BI y Grafana
9. Evolución a PLC/SCADA
10. Datos personales y seguridad
11. Capturas de los tableros

1 Usuarios y preguntas de negocio

El punto de partida no es el dato sino quién decide. Cada usuario tiene una frecuencia de consulta y un tipo de decisión distintos, y eso determina en qué herramienta vive su respuesta.

La fuente de esta identificación es el propio procedimiento **P-MTO-22 V1** (vigente desde el 14/05/2025), que describe la cadena de personas por las que pasa el dato: las operarias diligencian el formato hora a hora, producción lo remite a mantenimiento, mantenimiento lo digita en el Excel, y el coordinador de mantenimiento socializa un informe mensual «ante los jefes de las demás áreas y la alta dirección».

U1 · Operaria de la línea de envasado

Qué decide: si avisa o no. Es quien ve la máquina. **Frecuencia:** cada hora, durante el turno. **Dónde se le responde:** Grafana, en una pantalla de piso de planta.

#	Pregunta
P1.1	¿Voy al ritmo que debería, o me estoy quedando atrás?
P1.2	¿Cuánto tiempo llevo parada en este turno y por qué?
P1.3	¿Mi línea está peor que las otras tres ahora mismo?

> **Nota.** Hoy esta usuaria no recibe ninguna información de vuelta: entrega el formato en papel y nunca ve el resultado. Es el circuito de retroalimentación más corto y más barato de cerrar de todo el proyecto.

U2 · Supervisor de producción del turno

Qué decide: dónde pone al mejor técnico en las próximas dos horas, si para una línea para limpiarla, si cambia el orden de las órdenes. **Frecuencia:** varias veces por turno. **Dónde se le responde:** Grafana.

#	Pregunta
P2.1	¿Qué línea está en rojo en este momento y cuál es la causa vigente?
P2.2	¿El problema es que la máquina está parada, que corre lenta, o que está produciendo reproceso?
P2.3	¿Alguna línea dejó de reportar dato?
P2.4	¿Cómo va el turno comparado con las últimas 24 horas?
P2.5	¿Hay diferencias sostenidas entre el turno de noche y los de día?

U3 · Coordinador de mantenimiento

Qué decide: el plan semanal de mantenimiento, qué repuestos pide, a qué sistema le hace intervención de fondo. Es el dueño del P-MTO-22 y quien presenta el informe mensual. **Frecuencia:** diaria para operar, mensual para el comité. **Dónde se le responde:** Grafana para el día, Power BI para el mes.

#	Pregunta
P3.1	¿Qué pocas causas explican el 80 % del tiempo perdido? (Pareto)
P3.2	¿Qué **sistema físico** de la máquina me cuesta más tiempo, sin importar si el tiempo se perdió por falla, por servicios o por ajuste operativo?
P3.3	¿Cada cuántas horas falla cada línea (MTBF) y cuánto tardo en devolverla a producción (MTTR)?
P3.4	¿La confiabilidad está mejorando o empeorando respecto del año pasado?
P3.5	¿Cuánto del tiempo perdido es realmente imputable a mantenimiento?
P3.6	¿En qué proporción los registros llegan sin causa raíz especificada?

> **P3.2 es la pregunta que el Excel no puede responder.** Las ramas de subcódigos 1.x (falla electromecánica), 3.x (servicios) y 5.x (ajuste operativo) viven en columnas separadas de la hoja, así que nadie puede sumar el tiempo que cuesta el sistema dosificador. El modelo las une con un atributo conformado y la respuesta resulta ser contundente: **el sistema dosificador de pintura explica el 44,6 % del tiempo perdido por las causas con raíz identificable**: 992 de las 2.222,8 horas de los códigos 01/03/05, y el 11,8 % del tiempo perdido total de la planta.

U4 · Jefe de producción

Qué decide: la asignación de referencias a líneas, la secuencia de órdenes, la formación del personal. **Frecuencia:** semanal. **Dónde se le responde:** Power BI.

#	Pregunta
P4.1	¿Qué referencias nos alejan más del estándar de ingeniería?
P4.2	¿Cuánto cuesta el cambio de referencia y conviene agrupar órdenes?
P4.3	¿Hay diferencias de desempeño entre turnos?
P4.4	¿Cuánto producto dejamos de envasar por los paros?

U5 · Gerencia / alta dirección

Qué decide: inversión en equipos, contratación de un turno adicional, metas del año. **Frecuencia:** mensual, en el comité. **Dónde se le responde:** Power BI.

#	Pregunta
P5.1	¿Cuál es el OEE de la planta y cómo evolucionó frente al año anterior?
P5.2	¿Qué línea justifica una inversión y cuál solo necesita disciplina operativa?
P5.3	¿Cuánta capacidad instalada estamos dejando sin programar?
P5.4	¿Cuántas unidades dejamos de vender por el tiempo perdido evitable?
P5.5	¿Podemos confiar en estos números?

> **P5.5 no es una pregunta retórica.** Hoy el informe que llega al comité está inflado por 42 registros duplicados: **+129 horas, +1.019 pacas y +18,12 horas de paro**. Es poco en magnitud, pero es un error sistemático del que nadie se había dado cuenta, y nace de que el formulario del Excel no tiene ningún control que impida guardar dos veces el mismo registro.

Resumen: quién pregunta qué, y dónde

Usuario	Horizonte	Decisión típica	Herramienta
U1 Operaria	La hora en curso	Avisar	Grafana (piso de planta)
U2 Supervisor	El turno	Reasignar recursos	Grafana
U3 Coord. mantenimiento	Día y mes	Plan de mantenimiento, repuestos	Grafana + Power BI
U4 Jefe de producción	Semana	Secuencia y mezcla de producto	Power BI
U5 Gerencia	Mes y año	Inversión, metas, capacidad	Power BI

El patrón que explica el reparto de herramientas: **a medida que el horizonte de la decisión se alarga, la pregunta deja de ser «qué está pasando» y pasa a ser «qué está cambiando»**. La primera necesita el último dato; la segunda necesita comparar periodos. Son dos problemas técnicos distintos y por eso se resuelven con dos herramientas distintas, como se detalla en 08-power-bi-vs-grafana.md.

2 Diagnóstico de la fuente

Fuente analizada: `Seguimiento Temperas y Vinilos Actividad.xlsm` (4,2 MB, habilitado para macros). SHA-256: `c7d7eabbd55844757c2be07bd61efcee9eb5e0b03aaf9fd76b798737a92d5c55`. Procedimiento asociado: **P-MTO-22 V1**, vigente desde el 14/05/2025.

Todas las cifras de este documento se obtuvieron leyendo el archivo con `openpyxl` y son reproducibles ejecutando el ETL.

---

1. Estructura del archivo

El libro tiene **21 hojas**, de las cuales 5 están ocultas. La estructura real no coincide con lo que uno esperaría de una «base de datos»:

Hoja	Tamaño	Qué es	Oculta
`Base De Datos`	8.217 × 58	La tabla de hechos. **Encabezado en la fila 9**, datos desde la fila 10	
`Registro`	—	El formulario de captura hora a hora, con los tres botones de macro	
`Tiempos`	59 × 19	Parámetros. Contiene la lista de 45 operarios y el factor de producción	
`Tablas Desplegables`	262 × 52	**Catálogo máquina × referencia con la tasa ideal y las unidades por paca**	
`Base de datos de Sub codigos`	1.260 × 19	Registros de subcódigos	sí
`TABLA CODIGOS`	41 × 8	Catálogo de códigos y subcódigos de paro	sí
`Hoja4`	—	Tabla auxiliar de horas trabajadas por máquina y año	sí
`Calculadora de tiempos`	—	Hoja de cálculo auxiliar	sí
`TD_prodMaq`, `TD_prodAño`, `TD_prodCodigo`, `TD_fallaMecanica`, `TD_ajusteOperativo`, `TD_novPotencia`	—	Tablas dinámicas: lo que se lleva al comité	
`prodMaquina`, `prodAño`, `prodCodigo`, `fallaMecanica`, `ajusteOperativo`, `novPotencia`, `Hoja1`	—	Hojas de apoyo de los gráficos	

1.1. El dato que hacía falta estaba en una hoja auxiliar

El hallazgo estructural más importante: **la hoja de hechos no contiene lo necesario para calcular OEE, pero el libro sí**. La hoja `Tablas Desplegables` tiene un bloque con **135 pares máquina × referencia** y los encabezados:

```
maquina | Nombre de referencia | # colores | Pacas | Display | Unidades * paca | unidades *minuto
```

`unidades *minuto` es la **tasa ideal de producción**, es decir el estándar de ingeniería, y `Unidades * paca` es el factor que convierte las pacas que registra la operaria en unidades comparables. Con esos dos datos el **Rendimiento** del OEE se vuelve calculable. Nadie los estaba usando para eso: alimentan las listas desplegables del formulario.

1.2. Formato ancho: 18 pares de columnas

Las 58 columnas incluyen **18 pares `<minutos, horas>`**, uno por cada código de paro, más una columna de subcódigo para los códigos 01, 03 y 05. Un paro de 12 minutos por el código 05 se registra escribiendo 12 en la columna «cod05_min» y 0,2 en «cod05_hrs».

Esto es un formato de **reporte**, no de datos: funciona para imprimir y para hacer una tabla dinámica, pero impide preguntar «dame todos los paros de más de 30 minutos» sin recorrer 18 columnas. El ETL lo **despivota** a 16.482 filas, una por evento.

1.3. Volumen y cobertura temporal

Filas con datos	**8.208**
Rango	2022-01-01 a **2025-03-28**
2022	1.654 filas
2023	2.891 filas
2024	3.129 filas
2025	534 filas (año parcial)

---

2. Problemas de calidad de datos

Se documentaron **21 reglas de calidad** (DQ-01 a DQ-21) con conteos antes y después; el informe completo con esas cifras lo genera el propio ETL en `etl/salida/informe_calidad_datos.md`. Aquí van los hallazgos y por qué importan.

2.1. Duplicados exactos — 42 filas

42 filas son copia idéntica de otra. Aportan **129 horas, 1.019 pacas y 18,116667 horas de paro**.

Lo relevante no es la magnitud (0,34 % de las horas) sino que **las tablas dinámicas que hoy se llevan al comité los incluyen**, porque una tabla dinámica suma lo que encuentra. Es un error sistemático, no aleatorio: nace de que el botón «Ingreso total» del formulario no verifica si el registro ya existe.

2.2. Filas de continuación — 3.028 filas

El botón **«Ingreso subcódigo»**, documentado en el apartado 4.1.5 del P-MTO-22, «permite almacenar un subcódigo y continuar con el mismo registro». En la práctica genera una fila nueva **sin pacas y sin horas trabajadas**, que solo lleva el subcódigo y los minutos del paro.

Es decir: **el 37 % de las filas de la «base de datos» no son registros de producción**, son anexos de la fila anterior. Quien cuente filas para medir cualquier cosa se equivoca en un tercio.

El ETL las vincula a su cabecera en cascada de tres niveles (por fecha, máquina, operario, referencia y turno; luego sin turno; luego solo por fecha y máquina). Quedan **903 filas sin vincular**, porque no existe cabecera para esa fecha y máquina; de ellas solo **5 traen minutos de paro**, y suman **1,9167 horas: el 0,02 % del tiempo de paro**. Esas horas sí entran al total de tiempo perdido y al Pareto; lo único que no se puede es atribuirlas a un turno concreto.

2.3. Las tres columnas que deberían convertir pacas a unidades son inservibles

Columna	Encabezado	Contenido real
7	«Unidades producidas cada minuto»	**100 % vacía**
8	«Unidad por display»	**El TURNO**, en 687 filas
9	«Display por paca»	**100 % vacía**

Las 687 filas con la columna 8 informada **también** traen el turno en su columna correcta, así que es una copia redundante, no un respaldo (las 3 aparentes discrepancias son variantes de notación del mismo turno: `10pm–6am` frente a `10pm–6am (Turno 3)`).

Consecuencia práctica: la conversión de pacas a unidades **no puede salir de la hoja de hechos** y hay que tomarla del catálogo de `Tablas Desplegables`.

2.4. «Horas no trabajadas» no es tiempo de paro

Es el error de interpretación más fácil de cometer con esta fuente, y haberlo cometido habría invalidado todo el OEE:

- La suma de la columna es **41.519,85 h**, mayor que las 38.063,35 h trabajadas.
- **1.263 filas traen un 24 fijo** y 390 traen un 16.
- Una fila trae 32, que no cabe en un día.

No es tiempo perdido: es el **complemento del día de calendario** (24 − horas trabajadas). Se carga en una columna aparte y **no entra al OEE**.

2.5. Dos taxonomías de subcódigos conviviendo

Problema	Magnitud
Rama `4.x` histórica, en mayúsculas	**945 filas** en 8 variantes (p. ej. `4.2 SISTEMA DOSIFICADOR...`)
Rama `5.x` vigente	**2.149 filas** en 11 variantes
Variantes de escritura del subcódigo del código 01	**44** distintas, más las filas que lo dejan vacío
Errata en el **propio catálogo**: `1.4.3 Sensor`	debía ser `1.4.C`
Valor `Sin especificar`	**5.020** apariciones

La solución fue **confiar en el prefijo numérico y no en el texto**: el número es el dato fiable, el texto es lo que cada persona escribió ese día. La rama `4.x` se mapea a la `5.x` (4.1→5.1, 4.2→5.2, 4.3→5.3, 4.4→5.5, 4.5→5.6, 4.6→5.7, 4.7→5.8, 4.8→5.9) y la errata del catálogo se corrige.

2.6. Otros problemas documentados

Problema	Magnitud	Tratamiento
Referencias con erratas de digitación	52 valores distintos, 3 confusiones de nombre (`Alocdor`, `Stilo Kids`, `Klips 15cc (12col)`)	Consolidadas en 63 miembros limpios, conservando la lista de variantes
Columna «Tipo de paro»	19 variantes de **dos** taxonomías para ~13 conceptos	Consolidadas en 13 miembros
Turnos escritos de varias formas	`6am–2pm`, `6am–2pm (Turno 1)`, `Turno 1`	Resueltos al mismo miembro
Operarios	34 valores, incluidos los marcadores `No` y `No aplica`	Pseudonimizados; marcadores → miembro «Sin informar»
Paro mayor que las horas trabajadas	9 turnos; el peor con **18,17 h de paro en un turno de 10,5 h**	Se marca con bandera; es físicamente imposible, uno de los dos datos está mal
Horas trabajadas fuera del rango de un turno (más de 12 h)	1 turno declara **16 h**	Se marca con bandera; el valor no se corrige, la decisión es del dueño del dato
Duraciones atípicas	3 eventos; el mayor de **900 minutos** en el código 10	Se marcan con bandera y se conservan
Rendimiento implausible	22 turnos; el extremo declara un rendimiento del **1.561 %**, es decir **16 veces** lo que la máquina puede dar	Se marcan, se conservan para auditoría y se excluyen del indicador agregado
Pares máquina–referencia sin estándar	10	Resolución en cascada: catálogo → inferido por factor de producción → sin estándar
Hoja oculta `Base de datos de Sub codigos`	1.252 filas, de las cuales **982 ya están** en `Base De Datos`	**No se carga**: duplicaría 679,2 h de paro. Las 270 ausentes no tienen minutos

2.7. La completitud del registro mejoró drásticamente con el tiempo

Este es el hallazgo que condiciona qué se puede medir y desde cuándo:

Año	Con operario	Con referencia	Con turno	Con estándar	Índice de completitud
2022	0 %	0 %	0 %	0 %	**0 %**
2023	20 %	22 %	20 %	22 %	~21 %
2024	85 %	93 %	94 %	82 %	~88 %
2025	99 %	100 %	100 %	82 %	~95 %

En 2022 ninguna fila tiene operario, referencia ni turno. Solo fecha, máquina, horas, pacas y códigos de paro. Por eso:

- La **Disponibilidad** es calculable desde 2022.

- El **Rendimiento** —y con él el OEE— **no es calculable antes de 2023**, porque sin referencia no hay estándar contra el que comparar.

Presentar un OEE de 2022 sería inventarlo. El modelo devuelve NULL y el tablero lo muestra vacío, que es la respuesta honesta.

2.8. La fuente no mide defectos

No existe ninguna columna de unidades defectuosas, rechazadas o reprocesadas en unidades. El componente **Calidad** del OEE, por tanto, no es medible con esta fuente.

Se usa un **proxy declarado**: el tiempo del código 11 (Reproceso) convertido a unidades equivalentes. Son **9,05 horas en todo el histórico**, lo que da una calidad cercana al 100 % que con casi total seguridad es optimista. Se publica como cota inferior de la pérdida y se reporta siempre junto al OEE auditable (Disponibilidad × Rendimiento), para que se vea cuánto pesa la parte estimada.

Cerrar esta brecha requiere instrumentación, no mejor analítica: es el primer argumento de la propuesta de evolución a PLC/SCADA.

---

3. Limitaciones del esquema de reporte actual

El apartado 4.1.7 del P-MTO-22 enumera los gráficos que alimenta el Excel: producción general, producción por máquina (comparativo 2024 vs 2025), porcentaje de códigos de paro por máquina y análisis detallado de los códigos 01, 03 y 05. Con eso se arma el informe mensual del comité.

3.1. El Excel no calcula OEE

Lo que el Excel llama **«% Productividad»** es:

```
% Productividad = 1 − (tiempo de paro / horas trabajadas)
```

que es exactamente la **Disponibilidad** del OEE. Se verificó reproduciéndola desde los datos crudos y comparándola **a seis decimales** contra las tres tablas dinámicas del libro (35 contrastes, todos coincidentes).

Es decir: la planta cree medir productividad y mide **solo uno de los tres componentes**. Una línea parada el 20 % del tiempo pero corriendo al 60 % de su velocidad nominal aparece con un 80 % de «productividad», cuando su OEE real es del 48 %.

3.2. Las tablas dinámicas no responden la pregunta de mantenimiento

Los subcódigos de las ramas 1.x, 3.x y 5.x están en **columnas distintas** de la hoja. Una tabla dinámica opera sobre columnas, de modo que puede decir «cuánto tiempo costó el código 05», pero **no** «cuánto tiempo costó el sistema dosificador», que es la pregunta que permite decidir una intervención.

3.3. Las cifras del comité están infladas

Por los 42 duplicados: **+129 h, +1.019 pacas, +18,12 h de paro**. Una tabla dinámica no puede deduplicar.

3.4. El esquema es frágil por construcción

- **Encabezado en la fila 9**: cualquier inserción de filas arriba rompe las referencias.
- **18 pares de columnas**: añadir un código de paro nuevo obliga a insertar columnas y rehacer las fórmulas y las tablas dinámicas.
- **Macros con botones**: la trazabilidad depende de que el operador use el botón correcto; «Ingreso subcódigo» genera filas que parecen registros y no lo son.
- **Un solo archivo de 4,2 MB** en una unidad compartida: no admite dos personas digitando a la vez, no tiene historial de cambios y un `Ctrl+Z` mal dado destruye datos sin dejar rastro.
- **Sin control de duplicados, ni de rangos, ni de obligatoriedad**: por eso hay turnos de 32 horas y paros de 15,63 h en turnos de 8.

3.5. Lo que el esquema actual sí hace bien

Conviene decirlo, porque el diseño del modelo lo aprovecha:

- La **codificación de paros está bien pensada**: 18 códigos con una jerarquía de subcódigos que llega al sistema de la máquina. Es una taxonomía de mantenimiento seria, solo que atrapada en un formato que no la deja explotar.
- Los **estándares de ingeniería existen** y están definidos para 135 pares máquina × referencia.
- La **disciplina de registro mejoró** del 0 % al 95,3 % entre 2022 y 2025. Hay cultura de dato; lo que falta es la herramienta.

3 Catálogo de indicadores

Cada indicador lleva fórmula, unidad, granularidad, meta o umbral, fuente del dato y el usuario que lo consume (los códigos `U1`–`U5` y `P1.1`–`P5.5` remiten a 01-usuarios-y-preguntas-de-negocio.md).

Los indicadores están separados en dos bloques porque el enunciado pide distinguirlos: **A)** los que el P-MTO-22 ya reporta hoy, que hay que seguir entregando para no romper la continuidad del informe mensual; y **B)** los nuevos, cada uno con su justificación.

A. Indicadores que el P-MTO-22 ya reporta hoy

Estos tres se replican con la **misma fórmula** que usa el Excel. Se verificó la equivalencia reproduciéndolos desde los datos crudos y comparándolos **a seis decimales** contra las tres tablas dinámicas del libro: 35 contrastes, todos coincidentes. Eso permite decirle a la gerencia «es el mismo indicador que viene viendo», que es condición para que acepte el resto.

A1 · % Productividad (por máquina, mes y año)

Fórmula	`1 − (tiempo de paro / horas trabajadas)`
Unidad	Porcentaje
Granularidad	Máquina × mes; máquina × año
Meta	No había meta formal. Se propone **80 %**
Fuente	`dw.hecho_produccion_turno`: `horas_paro_total`, `horas_programadas`
Consumido por	U3, U5 (informe mensual del comité)
Equivalencia	**Es exactamente la Disponibilidad del OEE** (B1). Se mantiene el nombre antiguo como alias para la transición
Verificación	TD_prodMaq, Vinilos_2 2024: 0,624722 en el Excel y 0,624722 en el modelo

A2 · Participación de cada código de paro

Fórmula	`horas del código / horas trabajadas del periodo`
Unidad	Porcentaje
Granularidad	Máquina × código de paro × año
Umbral	Ninguno; es descriptivo
Fuente	`dw.hecho_paro` con `dw.dim_paro`
Consumido por	U3, U4
Verificación	TD_prodCodigo, Vinilos_2 2024: coincide a 6 decimales en los 18 códigos

A3 · Horas trabajadas y pacas producidas

Fórmula	`SUM(horas_trabajadas)`, `SUM(pacas_producidas)`
Unidad	Horas; pacas
Granularidad	Máquina × mes × año
Fuente	`dw.hecho_produccion_turno`
Consumido por	U4, U5
Verificación	Hoja4, horas 2023: V1 3.390,0 · V2 1.220,5 · V3 4.221,3 · V4 4.002,55, idénticas
Nota	El modelo entrega la cifra **depurada**. La del Excel está inflada en 129 h y 1.019 pacas por 42 duplicados exactos

---

B. Indicadores nuevos

B1 · Disponibilidad

Fórmula	`horas_operativas / horas_programadas`
Unidad	Porcentaje
Granularidad	Turno (base); se agrega a máquina × mes × año
Meta	**80 %**
Fuente	`dw.hecho_produccion_turno`
Consumido por	U2 (P2.2), U3, U5

Por qué es nuevo aunque el Excel ya lo calcule: el número es el mismo que A1, pero el *nombre* importa. Llamarlo «Disponibilidad» obliga a admitir que hay otros dos componentes y que hoy no se miden. Mientras se llame «productividad», la planta cree que ya mide todo.

B2 · Rendimiento

Fórmula	`unidades_producidas / (tasa_ideal × 60 × horas_operativas)`
Unidad	Porcentaje
Granularidad	Turno; se agrega a máquina × mes × año
Meta	**95 %**
Fuente	`hecho_produccion_turno` × `dim_estandar` (tasa ideal de `Tablas Desplegables`)
Consumido por	U2 (P2.2), U4 (P4.1), U5

Justificación. Es el componente que falta y el que explica la brecha oculta. El denominador usa el tiempo **operativo**, no el programado, para no contar dos veces la pérdida por paro: el tiempo parado ya lo castiga la Disponibilidad.

Solo se calcula si hay estándar de ingeniería y si el valor es plausible (≤ 150 % del máximo teórico). Si no, devuelve NULL: **nunca se inventa un valor**. Esto deja 2.686 de 5.138 turnos sin Rendimiento, casi todos de 2022, y eso es información, no una carencia.

B3 · Calidad (proxy declarado)

Fórmula	`1 − (unidades equivalentes de reproceso / unidades producidas)`
Unidad	Porcentaje
Granularidad	Turno
Meta	**99 %**
Fuente	Tiempo del código 11 (Reproceso), convertido a unidades con la tasa ideal
Consumido por	U2, U5

Justificación y advertencia. La fuente **no registra unidades defectuosas**, de modo que este componente no es medible. El proxy usa las 9,05 horas de reproceso de todo el histórico, lo que da una calidad cercana al 100 % que con casi total seguridad es optimista. Es una **cota inferior de la pérdida**: el OEE real no puede ser mejor que este. Se reporta siempre al lado del OEE auditable (B4) para que se vea cuánto pesa la estimación. Cerrarlo requiere instrumentación, no analítica.

B4 · OEE auditable · indicador principal del proyecto

Fórmula	`Disponibilidad × Rendimiento`, con los dos factores medidos sobre los **mismos** turnos
Unidad	Porcentaje

Granularidad	Turno; se agrega a máquina × mes × año
Población	Turnos con estándar de ingeniería y rendimiento plausible. Se declara siempre la **cobertura**: 0 % en 2022, 17–30 % en 2023, 70–91 % en 2024 y 48–100 % en 2025
Regla de agregación	**Razón de sumas**, nunca el promedio de los OEE por turno
Meta	**65 %** · **Umbral crítico 50 %** (dispara la alerta de Grafana)
Fuente	B1 × B2
Consumido por	U2, U3, U5 (P5.1, P5.2)

Justificación de la meta del 65 %. No es un número de manual. Es el nivel que **Vinilos_3 y Vinilos_4 ya sostienen** (74,4 % y 72,3 % en 2024) con los mismos equipos y el mismo producto. Una meta que dos de las cuatro líneas ya superan es demostradamente alcanzable, y eso quita la discusión de si el objetivo es realista.

Justificación del umbral crítico del 50 %. Es la frontera en la que dos líneas llevan años: **Vinilos_1 está en 49,7 % (2023) y 48,7 % (2024)**, y **Vinilos_2 en 45,7 % (2023) y 48,3 % en 2025**. Alertar por debajo de ese valor avisa de un problema real y no de ruido. Además, por debajo del 50 % la línea produce menos de la mitad de su capacidad mientras consume el 100 % de la mano de obra del turno, la energía y el aire comprimido: deja de cubrir su costo de operación.

Por qué los dos factores se miden sobre los mismos turnos. La Disponibilidad se puede calcular en cualquier turno, porque solo necesita horas. El Rendimiento no: exige un estándar de ingeniería, y la fuente solo lo trae en una parte de los registros. Si se multiplica la Disponibilidad de *todos* los turnos por el Rendimiento de *unos pocos*, el resultado no describe ninguna operación real. En Vinilos_1 2023, donde solo el 28 % de los turnos trae estándar, esa mezcla daba un OEE del **62,0 %** frente al **49,7 %** correcto, y fabricaba una «caída» de 13 puntos entre 2023 y 2024 que nunca ocurrió: la línea lleva dos años plana. Por eso el indicador restringe los dos factores al mismo subconjunto y publica al lado su cobertura.

Hay un hallazgo adicional en esa restricción: en 2023 los turnos **con** estándar tienen peor disponibilidad que el conjunto (61,4 % contra 76,6 % en Vinilos_1). El registro del estándar no era aleatorio. En 2024, con la cobertura por encima del 70 %, ambas cifras ya convergen (66,1 % y 65,7 %).

Por qué razón de sumas y no promedio de los OEE por turno. El OEE es un producto de dos ratios: el promedio de los productos no es el producto de los promedios. Agregarlo desde los sumandos (horas y unidades) es lo único que da el mismo valor a cualquier nivel de la jerarquía y lo único que concilia contra los totales de la fuente. Las dos definiciones se diferencian aquí en menos de un punto, pero solo una es reproducible desde la tabla de hechos.

Por qué se reporta `D × R` y no los tres componentes: porque sus dos factores se miden con el dato de la fuente, sin estimar nada. El OEE con los tres (B5) se publica al lado, pero el que sostiene una decisión de inversión es el auditable.

B5 · OEE completo

Fórmula	`Disponibilidad × Rendimiento × Calidad (proxy)`
Unidad	Porcentaje
Granularidad	Turno
Meta	65 %
Consumido por	U5

Justificación. Es la definición canónica de OEE. Se entrega para no inventar una métrica propia, pero marcada como dependiente de un proxy.

B6 · Tiempo perdido evitable

Fórmula	`SUM(horas_paro)` donde la naturaleza del código es «No planeado»
Unidad	Horas; y `% de paro evitable` sobre el total
Granularidad	Máquina × código × mes

Meta	Reducir un 20 % interanual
Fuente	`dw.hecho_paro` × `dim_paro.naturaleza_paro`
Consumido por	U3 (P3.5), U5 (P5.4)

Justificación. Sin esta separación el OEE castiga a la planta por hacer lo correcto: el mantenimiento preventivo, la capacitación y la pausa activa bajan el indicador igual que una avería. El dato del histórico: **64,9 % del tiempo perdido (5.468 h) es evitable** y 35,1 % (2.963 h) es programado.

B7 · Tiempo perdido por sistema físico de la máquina · el hallazgo

Fórmula	`SUM(horas_paro)` agrupado por `dim_paro.nombre_sistema`
Unidad	Horas; porcentaje del total
Granularidad	Sistema × máquina × mes
Umbral	Revisar cualquier sistema que supere el 15 % del tiempo perdido
Fuente	Atributo conformado `dim_paro.codigo_sistema`, construido por el equipo
Consumido por	U3 (P3.2)

Justificación. Es el indicador que **el Excel no puede calcular**, y el de mayor valor práctico. Las ramas de subcódigos 1.x (falla electromecánica), 3.x (servicios) y 5.x (ajuste operativo) viven en columnas separadas, así que nadie puede sumar lo que cuesta un sistema concreto. Al unificarlas:

Sobre las **2.222,8 h** de los códigos 01, 03 y 05, que son los únicos con árbol de causa raíz:

Sistema	Horas	% de 01/03/05	% acum.	% del total perdido
Sistema de dosificación de pintura	992,0	**44,6 %**	44,6 %	11,8 %
Sistema de tapado (transfer y pisador)	272,8	12,3 %	56,9 %	3,2 %
Sistema alimentador de tapa y tobogán	194,4	8,7 %	65,6 %	2,3 %
Sistema Video Jet (codificado)	188,5	8,5 %	74,1 %	2,2 %
Sistema etiquetadora	165,9	7,5 %	**81,6 %**	2,0 %

Un solo sistema explica el 44,6 % del tiempo perdido con causa raíz identificable y cinco explican el 81,6 %. Eso convierte una lista de 18 códigos en una decisión concreta de ingeniería.

> **El denominador importa.** El porcentaje es sobre las 2.222,8 h de los tres códigos que tienen subcódigos, no sobre las 8.431,5 h totales: los otros 15 códigos no registran el sistema afectado, así que atribuirles un sistema sería inventarlo. En términos del total perdido, el dosificador pesa el **11,8 %**, que sigue siendo el sistema más costoso de la planta con diferencia.

B8 · MTBF y MTTR

Fórmula	`MTBF = horas_operativas / nº de fallas` · `MTTR = horas de reparación / nº de fallas`
Unidad	Horas
Granularidad	Máquina × año
Meta	MTBF creciente interanual; MTTR < 1 h
Fuente	`dw.hecho_paro` restringido a los códigos 01 y 02
Consumido por	U3 (P3.3, P3.4)

Justificación. Son el lenguaje estándar de mantenimiento y distinguen dos problemas distintos que el tiempo total confunde: *fallar mucho* (MTBF bajo) y *tardar en arreglar* (MTTR alto). El primero se resuelve con rediseño o preventivo; el segundo, con repuestos y

formación. Solo cuentan los códigos 01 y 02 porque son las averías reales.

B9 · Utilización del calendario y TEEP

Fórmula	`horas_programadas / (días del año × 24)`
Unidad	Porcentaje
Granularidad	Máquina × año
Umbral	Informativo
Consumido por	U5 (P5.3)

Justificación. El OEE mide qué tan bien se usa el tiempo **que se programó**; este indicador mide **cuánto no se programó**, que es una decisión comercial y no de mantenimiento. Separarlos evita una conversación falsa: en 2024 Vinilos_4 programó el 60,3 % del calendario y Vinilos_2 solo el 22,0 %. Mejorar el OEE de Vinilos_2 no sirve de nada si el problema es que no hay órdenes que cargarle.

B10 · Unidades no producidas por paro

Fórmula	`tasa_ideal × 60 × horas_paro`
Unidad	Unidades
Granularidad	Evento de paro
Consumido por	U5 (P5.4)

Justificación. Traduce horas técnicas a lenguaje de negocio. «Perdimos 1.069 horas» no mueve a nadie en un comité; «dejamos de envasar X millones de unidades» sí.

B11 · Índice de completitud del registro · gobierno del dato

Fórmula	Promedio de cuatro proporciones: con operario, con referencia, con turno informado y con estándar disponible
Unidad	Porcentaje
Granularidad	Máquina × año
Meta	**95 %**
Fuente	Banderas de calidad de `dw.hecho_produccion_turno`
Consumido por	U3 (P3.6), U5 (P5.5)

Justificación. Es el indicador que sostiene a todos los demás. Pasa de **0 % en 2022 a 95 % en 2025** y explica por qué el Rendimiento no es calculable antes de 2023. Sin él, cualquier conclusión del tablero es frágil, y con él la conversación sobre disciplina de registro deja de ser una opinión.

B12 · Costo del cambio de referencia

Fórmula	`horas del código 07 / horas programadas` y `horas por cambio`
Unidad	Porcentaje; horas por evento
Granularidad	Máquina × trimestre
Consumido por	U4 (P4.2)

Justificación. Cuantifica el costo oculto de una mezcla de producto fragmentada: 620,8 h en 847 cambios, el 7,4 % de todo el tiempo perdido. Hoy nadie lo mide, y es una decisión de planeación, no de mantenimiento.

B13 · Semáforo de estado actual por línea

Fórmula	Verde ≥ 65 %, amarillo 50–65 %, rojo < 50 % de OEE de la última hora
Unidad	Categoría
Granularidad	Máquina, última hora reportada
Consumido por	U1 (P1.3), U2 (P2.1)

Justificación. Es el único indicador pensado para que se lea en dos segundos desde una pantalla de piso de planta. Va acompañado del panel de **líneas sin reportar**, porque un tablero en verde porque no llega información es peor que un tablero en rojo.

Resumen de metas y umbrales

Indicador	Meta	Umbral crítico	Cómo se justifica la meta
Disponibilidad	80 %	65 %	V3 y V4 ya la superaron (82,7 % y 81,9 % en 2023)
Rendimiento	95 %	85 %	V3 sostiene 96–98 % y V4 94–96 %, luego es alcanzable
Calidad (proxy)	99 %	97 %	Provisional: depende de medir defectos de verdad
OEE auditable	**65 %**	**50 %**	V3 y V4 sostienen 72–74 % (2024); V1 y V2 nunca han pasado del 53 %
% de paro evitable	< 50 %	—	Hoy está en 64,9 %
MTTR	< 1 h	2 h	—
Índice de completitud	95 %	80 %	2025 ya va en 95,3 %

4 Modelo dimensional

El diccionario de datos campo por campo está en 05-diccionario-de-datos.md, generado desde el catálogo de PostgreSQL. Este documento explica **las decisiones de diseño**.

---

1. Elección del esquema: constelación de hechos

Se eligió un **esquema en constelación** (*fact constellation*, también llamado galaxia): **tres tablas de hechos que comparten dimensiones conformadas**.

1.1. Por qué no una sola estrella

La tentación inicial es una única tabla de hechos de producción con los 18 códigos de paro como columnas, replicando la fuente. Se descartó porque:

- **No se puede preguntar por causa.** «Dame los paros de más de 30 minutos» exige recorrer 18 columnas. Y añadir un código 19 obligaría a alterar la tabla, reescribir las consultas y rehacer los tableros: exactamente la fragilidad que se quiere eliminar.
- **Desperdicia espacio y confunde.** De los 18 pares, la mayoría están vacíos en cada fila.
- **No admite los atributos del paro.** El subcódigo, el sistema físico, el área responsable y la naturaleza planeado/no planeado son atributos *del evento de paro*, no del turno. En formato ancho no tienen dónde vivir.

1.2. Por qué no un copo de nieve (snowflake)

Normalizar `dim_paro` en tres tablas (área → código → subcódigo) y `dim_referencia` en dos (línea comercial → referencia) sería más ortodoxo relacionalmente, pero:

- **Encarece la consulta que más se usa.** El Pareto de causas pasaría de un JOIN a tres, y es la consulta del tablero que más se refresca.
- **Complica el drill-down en Power BI.** Una jerarquía de cuatro niveles repartida en tres tablas obliga a relaciones encadenadas; en una sola tabla desnormalizada la jerarquía se define directamente.
- **No compra nada.** `dim_paro` tiene **65 filas**. El ahorro de espacio al normalizar es irrelevante y el costo de claridad es real.

Las dimensiones se dejan **desnormalizadas**, que es la recomendación de Kimball para un almacén orientado a consulta.

1.3. Por qué la constelación y no una estrella con un solo hecho

Porque hay **tres granos distintos** y mezclarlos produciría números falsos:

Hecho	Grano	Por qué no cabe en los otros
`hecho_produccion_turno`	Un turno de una máquina en una fecha, para una referencia	Las métricas de producción (horas, pacas) existen una sola vez por turno
`hecho_paro`	Un evento de paro de un código concreto dentro de un turno	Hay 0..18 paros por turno. Meterlos en el hecho de turno duplicaría las horas y las pacas en cada evento
`hecho_produccion_hora`	Una hora de reloj de una máquina	Es el grano que entregará el PLC. No existe en el Excel

El riesgo clásico de mezclarlos: si se pusiera un paro por fila junto a las pacas del turno, un turno con 5 paros reportaría **5 veces** sus pacas. La separación por grano es lo que lo impide.

1.4. Las dimensiones conformadas son la clave

`dim_fecha`, `dim_maquina`, `dim_turno` y `dim_referencia` son **las mismas tablas** para los tres hechos. Eso permite poner en un mismo informe el OEE del turno y el Pareto de causas filtrados por el mismo mes y la misma máquina, con la garantía de que ambos hablan de lo mismo.

No existe ninguna relación directa entre las tablas de hechos. Es deliberado: en una constelación los hechos se relacionan *entre sí* exclusivamente a través de las dimensiones conformadas. Unirlos crearía caminos de filtro ambiguos en Power BI y conteos duplicados en SQL.

> `hecho_paro.produccion_turno_id` apunta al turno, pero **no se declara como relación en el modelo semántico**: existe solo para trazabilidad y auditoría, no como camino de filtro.

---

2. Grano declarado de cada tabla de hechos

`dw.hecho_produccion_turno` — 5.138 filas

> **Un registro por turno de producción de una máquina en una fecha, para una referencia concreta.**

Si durante el mismo turno la línea cambia de referencia, la fuente genera un registro nuevo; `consecutivo_registro` los distingue y **forma parte del grano**. La clave única es `(fecha_key, maquina_key, turno_key, referencia_key, consecutivo_registro)`.

De las 8.208 filas del Excel, 5.138 son registros de turno; las otras 3.070 son 3.028 continuaciones del botón «Ingreso subcódigo» y 42 duplicados exactos. **La suma cuadra exactamente** y ese cuadre es una de las pruebas de conciliación.

`dw.hecho_paro` — 16.482 filas

> **Un registro por evento de paro de un código concreto dentro de un turno de una máquina.**

Resultado de despivotar los 18 pares `<minutos, horas>`. Solo se crea fila cuando los minutos son mayores que cero.

`dw.hecho_produccion_hora`

> **Un registro por hora de reloj y máquina.**

Es el grano que entregaría un historiador de PLC/SCADA. Hoy lo alimenta el simulador; el ETL del Excel no escribe aquí porque la fuente histórica no tiene grano horario.

Aditividad de las métricas

Distinguirla evita el error más común al construir el tablero:

Tipo	Métricas	Se puede sumar
Aditivas	horas programadas, horas de paro, horas operativas, pacas, unidades, eventos	En todas las dimensiones
Semiaditivas	`tasa_ideal_unid_min`	En ninguna: es un atributo del estándar que se congela en el hecho
No aditivas (ratios)	Disponibilidad, Rendimiento, Calidad, OEE	**Nunca.** Hay que recalcularlas desde los numeradores y denominadores agregados

Por eso las medidas DAX se definen como `DIVIDE(SUM(...), SUM(...))` y **no** como `AVERAGE(oee_ad)`. Promediar el OEE de 5.138 turnos da un número que no significa nada, porque un turno de 2 horas pesaría igual que uno de 12. La columna `oee_ad` existe en el hecho para poder auditar fila a fila contra la fuente, no para agregarla.

Hay un segundo requisito, menos evidente y más fácil de incumplir: cuando un indicador es el **producto** de dos ratios, los dos tienen que medirse sobre las **mismas filas**. La Disponibilidad se puede calcular en cualquier turno porque solo necesita horas; el Rendimiento exige un estándar de ingeniería, y la fuente solo lo trae en una parte de los registros. Multiplicar la Disponibilidad de todos los turnos por el Rendimiento de unos pocos produce un número que no describe ninguna operación: en Vinilos_1 2023, con un 28 % de cobertura, daba un OEE del 62,0 % frente al 49,7 % real, e inventaba una caída de 13 puntos hacia 2024 que nunca existió. De ahí las medidas `Disponibilidad (OEE)`, `Horas operativas (OEE)` y `Horas programadas (OEE)`, restringidas al mismo subconjunto que el Rendimiento, y la medida `Cobertura del OEE`, que se publica al lado del indicador para que el lector sepa sobre qué fracción del periodo está mirando.

---

3. Dimensiones, atributos y jerarquías

Dimensión	Filas	Jerarquías	Nota
`dim_fecha`	1.826	Año → Trimestre → Mes → Día · Año → Semana ISO → Día	**Construida por el equipo**
`dim_maquina`	4	Planta → Línea	Contiene el factor de producción
`dim_turno`	8	Tipo de jornada → Turno	
`dim_referencia`	63	Línea comercial → Referencia → Presentación	
`dim_paro`	65	**Área → Código → Sistema → Causa raíz**	Jerarquía desbalanceada
`dim_estandar`	137	—	**SCD Tipo 2**
`dim_tipo_paro_cabecera`	13	Grupo → Tipo	
`dim_area_involucrada`	7	—	
`dim_operario`	44	—	Pseudonimizada
`dim_personal_mantenimiento`	39	—	Pseudonimizada

3.1. `dim_fecha`: la dimensión construida por el equipo

El enunciado pide al menos una dimensión construida por el equipo. `dim_fecha` **no existe en la fuente**: el Excel solo tiene una columna de fecha. Se generó en el ETL con 1.826 días (2022–2026) y 23 atributos. Los que no son obvios:

- **`es_festivo` y `nombre_festivo`** — festivos de Colombia calculados en código: los fijos, los derivados del Domingo de Pascua con el **algoritmo de Butcher**, y los trasladables al lunes siguiente según la **Ley 51 de 1983 (Ley Emiliani)**. Permite separar la producción de día hábil de la de festivo, que tiene otro costo de mano de obra.
- **`fecha_key_anio_ant` y `anio_mes_anio_ant`** — la llave del mismo día y del mismo mes del año anterior, **precalculadas**. Convierte cualquier comparativo interanual en SQL en un JOIN en lugar de aritmética de fechas en cada consulta.
- **`anio_semana_iso` aparte de `anio`** — porque en la primera y la última semana del año difieren, y agregarlas por `anio` partiría semanas.
- **`mes` numérico junto a `nombre_mes`** — para que los meses no salgan en orden alfabético en los tableros.
- Los nombres de mes y día se generan **en el ETL y no con `to_char`**, para no depender de la configuración regional del servidor.

`fecha_key` es un entero `AAAAMMDD` en lugar de una fecha: los índices y los JOIN son más compactos y la llave se lee sin consultar la dimensión.

3.2. Miembros de relleno en lugar de NULL

Todas las dimensiones reservan la llave **0** para un miembro «Sin informar» o «No aplica». Las llaves foráneas de los hechos son `NOT NULL`.

Razón: un `NULL` en una llave foránea rompe el `INNER JOIN` y la fila desaparece del informe sin avisar. Con miembro de relleno, el turno sin operario sigue sumando sus horas y aparece etiquetado como «Sin informar», que es la verdad. Es la diferencia entre un informe que miente por omisión y uno que declara lo que no sabe.

---

4. Cómo se modela la jerarquía de los paros

Es la decisión de diseño más delicada del proyecto, por tres razones.

4.1. La jerarquía real es desbalanceada (*ragged*)

Nivel	Atributo	Cardinalidad
1	`area_impacto`	6 áreas
2	`etiqueta_codigo_paro`	18 códigos
3	`nombre_sistema`	14 sistemas

Nivel	Atributo	Cardinalidad
4	`nombre_subcodigo`	Causa raíz

Solo los códigos 01, 03 y 05 tienen subcódigos. Los otros 15 terminan en el nivel 2. Una jerarquía donde las ramas tienen profundidad distinta es *ragged*, y hay dos formas de resolverlo:

- Dejar `NULL` en los niveles que no aplican. El drill-down del tablero aterriza en una fila en blanco y el usuario no sabe si falta el dato o no existe el nivel.
- **Rellenar con miembros explícitos.** Es lo que se hizo: `'N/A'` cuando el código no admite subcódigo, y `'SIN-ESP'` cuando sí lo admite pero la fuente no lo especificó.

Son dos cosas distintas y por eso se distinguen. `'N/A'` significa «este nivel no existe para esta rama»; `'SIN-ESP'` significa «este nivel existe y falta el dato». Confundirlas arruinaría el indicador de completitud: medido sobre los 18 códigos daría un 78 % de registros «incompletos», cuando el valor real —medido solo donde el subcódigo tiene sentido— es del **2,9 %** (107 de 3.691 eventos). La columna `admite_subcodigo` es lo que permite hacer esa distinción, y `nivel_detalle` dice hasta dónde se puede bajar en cada rama.

4.2. El nivel 3 es un atributo conformado construido por el equipo

Este es el aporte de diseño más valioso. En la fuente los subcódigos están organizados por **rama numérica**, que corresponde al *tipo de problema*:

- `1.x` → falla electromecánica (código 01)
- `3.x` → novedad en sistemas de potencia (código 03)
- `5.x` → ajuste operativo (código 05)

Pero `1.4` (sensor del dosificador), `3.2` (aire del dosificador) y `5.2` (ajuste del dosificador) **se refieren al mismo sistema físico**. En el Excel viven en columnas distintas, así que nadie puede sumar lo que cuesta el dosificador.

El ETL deduce el **sistema físico** del prefijo numérico del subcódigo y lo guarda en `codigo_sistema` / `nombre_sistema`. Así, las tres ramas convergen en el sistema al que todas apuntan.

Resultado: **el sistema de dosificación de pintura explica el 44,6 % del tiempo perdido por causas con raíz identificable** (992 h de las 2.222,8 h de los códigos 01/03/05, es decir el 11,8 % del tiempo perdido total) y cinco sistemas explican el 81,6 %. Es una pregunta que la fuente contiene pero no puede responder, y el modelo sí.

4.3. Dos taxonomías conviviendo

La fuente tiene una rama `4.x` histórica y una `5.x` vigente para los mismos conceptos, y 45 variantes de escritura para unos 25 subcódigos del código 01. La regla que se aplicó: **confiar en el prefijo numérico, no en el texto**. El número es el dato fiable; el texto es lo que cada persona escribió ese día. Se mapea `4.1→5.1, 4.2→5.2, 4.3→5.3, 4.4→5.5, 4.5→5.6, 4.6→5.7, 4.7→5.8, 4.8→5.9` y se corrige la errata del propio catálogo (`1.4.3` debía ser `1.4.C`).

`dim_tipo_paro_cabecera` guarda en `taxonomia_origen` de cuál de las dos taxonomías viene cada miembro, para poder medir cuánto del histórico usa la nomenclatura antigua.

4.4. Por qué una sola tabla y no tres

Los cuatro niveles están **desnormalizados en `dim_paro`**, con 65 filas. Normalizarlos en tres tablas convertiría el Pareto —la consulta más frecuente del tablero— en tres JOIN, y complicaría el drill-down de Power BI, a cambio de un ahorro de espacio irrelevante.

---

5. Matriz de bus

Relaciona los procesos de negocio con las dimensiones conformadas. Las columnas con ✓ en varias filas son las dimensiones que permiten cruzar procesos.

Proceso de negocio →	Fecha	Máquina	Turno	Referencia	Estándar	Paro	Tipo paro cab.	Área invol.	Operario	Personal mto.
Producción por turno (`hecho_produccion_turno`)	✓	✓	✓	✓	✓		✓		✓	
Eventos de paro (`hecho_paro`)	✓	✓	✓	✓		✓		✓	✓	✓
Telemetría horaria (`hecho_produccion_hora`)	✓	✓	✓	✓		✓			✓	
Calidad del dato (`aud.regla_calidad`)	✓									
Conciliación con la fuente (`aud.conciliacion`)	✓	✓				✓				

Cómo se lee:

- **Fecha, Máquina, Turno y Referencia** son las cuatro dimensiones verdaderamente conformadas: aparecen en los tres procesos productivos. Son las que se usan como segmentaciones globales en los tableros.
- **Paro** solo aplica donde hay eventos de paro. En producción por turno el paro está *agregado* (`horas_paro_total`), no detallado: son granos distintos.
- **Estándar** solo aplica a producción por turno, porque es donde se compara contra la tasa ideal.
- **Personal de mantenimiento** solo aplica a eventos de paro: la fuente lo registra cuando alguien atiende una avería, no por turno.
- Los dos últimos procesos son de **auditoría**, no de negocio, pero se incluyen porque comparten `dim_fecha` y permiten responder «¿podemos confiar en el dato de este mes?» con la misma segmentación de tiempo que el resto.

---

6. Dimensión de cambio lento (SCD)

6.1. Qué dimensión lo necesita y por qué

`dim_estandar` es la única que lo requiere de verdad, y el razonamiento es el que decide el tipo:

La tasa ideal de producción de un par máquina–referencia **cambia con el tiempo**: se reacondiciona la máquina, se cambia el molde del envase, ingeniería revisa el estándar. Y el Rendimiento del OEE se calcula **dividiendo por ese estándar**.

Si se sobrescribiera el estándar (Tipo 1), **todo el histórico de Rendimiento se recalcularía hacia atrás**. Un turno de 2023 que rindió al 95 % contra el estándar de entonces podría aparecer al 78 % porque en 2025 se subió el estándar. El indicador del pasado cambiaría sin que nada hubiera pasado en el pasado, y el informe de este mes dejaría de cuadrar con el del mes anterior. Eso destruye la credibilidad del tablero más rápido que cualquier error de cálculo.

6.2. Tipo elegido: SCD Tipo 2

Columna	Función
`version`	Número de versión, desde 1
`valido_desde` / `valido_hasta`	Vigencia; `NULL` en la versión actual
`es_vigente`	Bandera de la versión actual
`motivo_cambio`	Por qué se cambió, para auditar

Un **índice único parcial** garantiza que solo exista una versión vigente por par máquina–referencia:

```
CREATE UNIQUE INDEX uq_dim_estandar_vigente
    ON dw.dim_estandar (maquina_key, referencia_key)
    WHERE es_vigente;
```

Además, `hecho_produccion_turno` **copia la tasa ideal** en `tasa_ideal_unid_min`. Así, incluso si alguien manipulara la dimensión, el indicador histórico ya calculado no se altera: el hecho congela el estándar que regía en ese momento.

`origen_estandar` registra el nivel de confianza: `'Catalogo'` si venía en `Tablas Desplegables`, `'Inferido'` si se dedujo de otra línea ajustando por el factor de producción. De los **137 miembros: 132 vienen del catálogo y 5 se infirieron**. Quedan además **10 pares máquina–referencia sin estándar**, que no generan miembro: sus turnos se marcan con `tiene_estandar = false` y el Rendimiento queda en NULL.

6.3. Las otras dimensiones y por qué no las necesitan

Dimensión	Tipo	Razón
`dim_referencia`	**Tipo 1** (sobrescribir)	Los cambios son correcciones de erratas de digitación. Conservar «Alocdor» como versión histórica sería conservar un error, no un hecho del negocio. `variantes_fuente` guarda las variantes para auditar
`dim_maquina`	**Tipo 1**	Un cambio de nombre es cosmético. Si cambiara el `factor_produccion` habría que pasarla a Tipo 2, por el mismo argumento de `dim_estandar`; hoy no ha cambiado
`dim_operario`	**Tipo 1**	Un cambio de rol no debe reescribir el histórico, pero analizar por persona está **fuera del alcance declarado** del tratamiento de datos personales, así que no se versiona
`dim_paro`	**Tipo 1**	El catálogo del P-MTO-22 es normativo. Si cambiara, interesa el código vigente; `taxonomia_origen` ya deja rastro de la convivencia de taxonomías
`dim_fecha`	No aplica	El calendario no cambia

---

7. Restricciones e índices

7.1. Restricciones

- **Llaves foráneas en todas las llaves de dimensión**, todas `NOT NULL` gracias a los miembros de relleno. La base **impide** cargar un hecho que apunte a una dimensión inexistente, de modo que el error de integridad no depende de que el ETL esté bien escrito.
- **21 restricciones `CHECK`** que codifican reglas de negocio: que los ratios estén entre 0 y 1, que las horas operativas sean coherentes con programadas menos paro, que los minutos de paro no sean negativos, que la suma de paro planeado y no planeado dé el total. Están listadas en el diccionario de datos.
- **Claves únicas de negocio** además de la primaria técnica: la del grano en `hecho_produccion_turno`, y `(instante, maquina_key)` en `hecho_produccion_hora`, que permite al simulador usar `ON CONFLICT`.

7.2. Estrategia de índices, justificada por el tipo de consulta

63 índices en `dw`, con cinco criterios:

1. **Un índice por cada llave foránea.** PostgreSQL **no** los crea automáticamente, y sin ellos cada JOIN con una dimensión es un recorrido completo de la tabla de hechos.
2. **Índices compuestos con `fecha_key` primero.** Prácticamente toda consulta analítica filtra por periodo; poner la fecha al frente permite usar el índice tanto para `WHERE anio = 2024` como para los agrupamientos por mes.
3. **Índices parciales** para los subconjuntos que el tablero consulta siempre: los turnos con estándar y rendimiento plausible, los paros no planeados, la versión vigente del estándar. Un índice parcial es más pequeño y cabe mejor en memoria.
4. **Índice BRIN sobre `hecho_produccion_hora(instante)`.** Es una tabla de serie de tiempo que crece de forma monótona y se consulta por rangos recientes. Un BRIN ocupa una fracción de lo que ocuparía un B-tree y para este patrón rinde igual.
5. **Ningún índice sobre las columnas de métricas.** Nadie filtra por `WHERE pacas_producidas = 37`; indexarlas solo encarecería la carga.

Se usa `INCLUDE` en algunos índices para habilitar *index-only scans* en las consultas del Pareto, que leen pocas columnas sobre muchas filas.

5 Diccionario de datos

> **Este documento se genera automaticamente** leyendo el catalogo de PostgreSQL (`herramientas/gen_diccionario.py`). Los tipos, las llaves y las restricciones son los que la base tiene de verdad, no una transcripcion; y las descripciones salen de los `COMMENT` del script `sql/init/70_diccionario.sql`, de modo que el diccionario y la base no pueden divergir.

Cada descripcion de columna tiene tres partes:

- **La descripcion** de que representa el campo.
- **`ORIGEN:`** de donde sale el dato. `construida` significa que el ETL la genera y no existe en la fuente; si viene del Excel, se nombra la columna y la hoja exactas.
- **`REGLA:`** la transformacion que se le aplico.

El esquema `dw` tiene **13 tablas** y **187 columnas**, todas documentadas.

Indice

- `dw.hecho_produccion_turno` — Hecho, 38 columnas
- `dw.hecho_paro` — Hecho, 21 columnas
- `dw.hecho_produccion_hora` — Hecho, 22 columnas
- `dw.dim_fecha` — Dimension, 23 columnas
- `dw.dim_maquina` — Dimension, 9 columnas
- `dw.dim_turno` — Dimension, 11 columnas
- `dw.dim_referencia` — Dimension, 12 columnas
- `dw.dim_estandar` — Dimension, 12 columnas
- `dw.dim_paro` — Dimension, 16 columnas
- `dw.dim_tipo_paro_cabecera` — Dimension, 6 columnas
- `dw.dim_area_involucrada` — Dimension, 4 columnas
- `dw.dim_operario` — Dimension, 8 columnas
- `dw.dim_personal_mantenimiento` — Dimension, 5 columnas

`dw.hecho_produccion_turno`

Tabla de hechos de produccion por turno.

Grano declarado. Un registro por turno de produccion de una maquina en una fecha, para una referencia concreta. Si en el mismo turno la linea cambia de referencia, la fuente genera un registro nuevo, y el consecutivo lo distingue. 5.138 filas.

Filas cargadas: aproximadamente 5.138.

Columna	Tipo	Clave	Descripcion, origen y regla
`produccion_turno_id`	`bigint NOT NULL`	PK	Llave primaria tecnica de la fila. ORIGEN: construida.
`fecha_key`	`integer NOT NULL`	FK → `dim_fecha` UQ	Llave a dim_fecha. ORIGEN: columna 'Dia' de la hoja Base De Datos. REGLA: se convierte a entero AAAAMMDD.
`maquina_key`	`smallint NOT NULL`	FK → `dim_maquina` UQ	Llave a dim_maquina. ORIGEN: columna 'Maquina'.
`turno_key`	`smallint NOT NULL`	FK → `dim_turno` UQ	Llave a dim_turno. ORIGEN: columna 'Turno', con respaldo en la columna 8 ('Unidad por display'), que el formulario reutilizo para guardar el turno. REGLA: si la fuente no trae turno se asigna el miembro de relleno y se marca turno_imputado; ocurre en 2.409 de 5.138 turnos.
`operario_key`	`integer NOT NULL`	FK → `dim_operario` UQ	Llave a dim_operario. ORIGEN: columna 'Operario'. REGLA: pseudonimizado.

Columna	Tipo	Clave	Descripcion, origen y regla
`referencia_key`	`integer NOT NULL`	FK → `dim_referencia` UQ	Llave a dim_referencia. ORIGEN: columna 'Referencia'.
`estandar_key`	`integer`	FK → `dim_estandar`	Llave a la version VIGENTE del estandar en dim_estandar. ORIGEN: construida. REGLA: resolucion en cascada de tres niveles: catalogo exacto del par maquina-referencia; si no existe, estandar de otra linea ajustado por el factor de produccion; si tampoco, 'sin estandar'.
`tipo_paro_key`	`smallint NOT NULL`	FK → `dim_tipo_paro_cabecera`	Llave a dim_tipo_paro_cabecera. ORIGEN: columna 'Tipo de paro'.
`consecutivo_registro`	`integer NOT NULL`	UQ	Numero de registro del turno cuando hay varios para la misma fecha, maquina y turno. ORIGEN: construida. REGLA: forma parte del grano; la fuente permite varios registros por turno si cambia la referencia.
`fila_origen_excel`	`integer NOT NULL`		Numero de fila en la hoja 'Base De Datos' del Excel (la fila 10 es la primera con datos). ORIGEN: construida. REGLA: trazabilidad: permite volver a la celda exacta del Excel ante cualquier duda.
`horas_programadas`	`numeric(10,6) NOT NULL`		Horas que la planta programo para producir en el turno. ORIGEN: columna 'Horas trabajadas'. REGLA: se carga tal cual; es el denominador de la Disponibilidad y la base de toda la conciliacion contra el Excel. *(Valor por defecto: `0`.)*
`horas_no_programadas`	`numeric(10,6)`		Horas de calendario sin produccion declaradas por la fuente. ORIGEN: columna 'Horas no trabajadas'. REGLA: ATENCION, NO ES TIEMPO DE PARO. Su suma (41.519,85 h) supera las horas trabajadas y 1.263 filas traen un 24 fijo: es el complemento del dia, no una perdida. Se carga aparte y NO entra al OEE; incluirla seria el error de interpretacion mas facil de cometer con esta fuente.
`horas_paro_total`	`numeric(10,6) NOT NULL`		Horas totales de paro del turno. ORIGEN: reconstruida sumando los 18 pares de columnas de paro. REGLA: NO se copia la columna 'Tiempo de paro' del Excel; se recalcula desde el detalle y despues se CONCILIA contra ella. Coincidir demuestra que el despivote no perdio ni duplico un minuto. *(Valor por defecto: `0`.)*
`horas_paro_planeado`	`numeric(10,6) NOT NULL`		Horas de paro de naturaleza planeada. ORIGEN: derivada. REGLA: suma de los paros cuyos codigos son 04, 08, 15, 16, 17 o 18. *(Valor por defecto: `0`.)*
`horas_paro_no_planeado`	`numeric(10,6) NOT NULL`		Horas de paro EVITABLE. ORIGEN: derivada. REGLA: horas_paro_total menos horas_paro_planeado. Es la cifra sobre la que la gerencia puede actuar. *(Valor por defecto: `0`.)*
`horas_operativas`	`numeric(10,6) NOT NULL`		Horas en que la linea estuvo efectivamente produciendo. ORIGEN: derivada. REGLA: horas_programadas menos horas_paro_total, acotada en cero. *(Valor por defecto: `0`.)*
`eventos_paro`	`smallint NOT NULL`		Numero de eventos de paro del turno. ORIGEN: derivada. REGLA: conteo de pares de columnas con minutos mayores que cero. *(Valor por defecto: `0`.)*
`pacas_producidas`	`integer NOT NULL`		Pacas producidas en el turno. ORIGEN: columna 'Pacas producidas'. REGLA: se carga tal cual; es la unidad en que registra el operario. *(Valor por defecto: `0`.)*
`unidades_producidas`	`bigint NOT NULL`		Produccion convertida a unidades comparables. ORIGEN: derivada. REGLA: pacas_producidas por unidades_por_paca de la referencia. Sin esta conversion no se pueden comparar referencias de 6 y de 12 colores, ni calcular Rendimiento. *(Valor por defecto: `0`.)*
`tasa_ideal_unid_min`	`numeric(8,3)`		Tasa ideal del estandar vigente aplicado. ORIGEN: dim_estandar. REGLA: se copia al hecho para congelar el estandar que regia en ese momento; si el estandar cambia luego, el indicador historico no se altera.
`unidades_teoricas`	`bigint`		Unidades que el estandar permitiria en el tiempo PROGRAMADO. ORIGEN: derivada. REGLA: tasa por 60 por horas_programadas. Es la capacidad nominal del turno.
`unidades_posibles`	`bigint`		Unidades que el estandar permitiria en el tiempo OPERATIVO. ORIGEN: derivada. REGLA: tasa por 60 por horas_operativas. Es el denominador del Rendimiento: compara contra lo que se pudo hacer con la maquina andando, no con la capacidad nominal, para no contar dos veces la perdida por paro.
`unidades_perdidas_paro`	`bigint`		Unidades que se dejaron de producir por los paros. ORIGEN: derivada. REGLA: tasa por 60 por horas_paro_total. Traduce el tiempo perdido al lenguaje del negocio.
`disponibilidad`	`numeric(7,6)`		Primer componente del OEE. ORIGEN: derivada. REGLA: horas_operativas / horas_programadas. REPRODUCE EXACTAMENTE el '% Productividad' que el Excel calcula hoy, verificado a seis decimales contra las tablas dinamicas. Al agregarla se usan TODOS los turnos, porque solo necesita horas; el factor de disponibilidad que entra en el OEE se restringe en cambio a los turnos con estandar, para medir la misma poblacion que el Rendimiento (ver la vista v_oee_mes_maquina, columna disponibilidad_oee).

Columna	Tipo	Clave	Descripcion, origen y regla
`rendimiento`	`numeric(12,6)`		Segundo componente del OEE. ORIGEN: derivada. REGLA: unidades_producidas / unidades_posibles. NULL si no hay estandar: nunca se inventa un valor. El Excel no lo calcula.
`calidad_proxy`	`numeric(7,6)`		Tercer componente del OEE, como PROXY declarado. ORIGEN: derivada. REGLA: la fuente NO registra unidades defectuosas, asi que la perdida se estima con el tiempo de reproceso (codigo 11) convertido a unidades. Es una COTA INFERIOR: el OEE real no puede ser mejor que este. Es la principal limitacion del modelo y esta declarada, no disimulada.
`oee_ad`	`numeric(12,6)`		OEE auditable del turno: disponibilidad * rendimiento. ORIGEN: derivada. REGLA: es la version que se reporta, porque sus dos componentes se miden con el dato de la fuente sin estimar nada. NO AGREGAR ESTA COLUMNA: es un ratio no aditivo y existe solo para auditar fila a fila. El OEE de un periodo se recalcula como razon de sumas sobre los turnos con tiene_estandar y sin rendimiento_implausible; promediarla, aunque sea ponderando por horas, da otro numero.
`oee_completo`	`numeric(12,6)`		OEE con los tres componentes, usando el proxy de Calidad. ORIGEN: derivada. REGLA: se publica junto al auditable para que se vea cuanto pesa la parte estimada.
`es_registro_completo`	`boolean NOT NULL`		Verdadero si el formato se diligencio completo. ORIGEN: derivada. REGLA: exige operario, referencia y turno informados y estandar disponible. *(Valor por defecto: `true`.)*
`tiene_estandar`	`boolean NOT NULL`		Verdadero si existe estandar para el par maquina-referencia. ORIGEN: derivada. REGLA: si es falso, el Rendimiento y el OEE quedan en NULL. *(Valor por defecto: `false`.)*
`paro_excede_programado`	`boolean NOT NULL`		Verdadero si el paro declarado supera las horas trabajadas. ORIGEN: derivada. REGLA: bandera de calidad; 9 turnos lo cumplen, el peor con 15,63 h de paro en un turno de 8 h. Es imposible fisicamente, de modo que uno de los dos datos esta mal. *(Valor por defecto: `false`.)*
`horas_fuera_de_rango`	`boolean NOT NULL`		Verdadero si las horas trabajadas no son plausibles. ORIGEN: derivada. REGLA: bandera de calidad; una fila declara 32 h en un dia. *(Valor por defecto: `false`.)*
`turno_imputado`	`boolean NOT NULL`		Verdadero si el turno se asigno porque la fuente no lo traia. ORIGEN: derivada. REGLA: hace visible el dato imputado para que nadie lo confunda con dato real. *(Valor por defecto: `false`.)*
`operario_no_informado`	`boolean NOT NULL`		Verdadero si la fuente no registro el operario. ORIGEN: derivada. *(Valor por defecto: `false`.)*
`referencia_no_informada`	`boolean NOT NULL`		Verdadero si la fuente no registro la referencia. ORIGEN: derivada. *(Valor por defecto: `false`.)*
`rendimiento_implausible`	`boolean NOT NULL`		Verdadero si el rendimiento supera el 150% del maximo teorico. ORIGEN: derivada. REGLA: hallazgo real de la carga: el caso extremo declara un rendimiento del 1.561%, es decir 16 veces el maximo del estandar. No es una linea excepcional, es un dato erroneo. Se CONSERVA el valor para poder auditarlo, pero se excluye del indicador agregado y del indice parcial. *(Valor por defecto: `false`.)*
`ejecucion_id`	`bigint NOT NULL`		Identificador de la ejecucion del ETL que cargo la fila. ORIGEN: construida. REGLA: permite auditar y revertir una carga concreta.
`cargado_en`	`timestamp with time zone NOT NULL`		Marca de tiempo de la carga. ORIGEN: construida. REGLA: default now(). *(Valor por defecto: `now()`.)*

Restricciones de validacion (CHECK). Son las reglas de negocio que la base impide violar, de modo que un dato incoherente no puede entrar ni por error de programacion:

- `ck_hpt_horas_prog`: `CHECK (((horas_programadas >= (0)::numeric) AND (horas_programadas <= (24)::numeric)))`
- `ck_hpt_pacas`: `CHECK ((pacas_producidas >= 0))`
- `ck_hpt_paro_partes`: `CHECK ((abs((horas_paro_total - (horas_paro_planeado + horas_paro_no_planeado))) < 0.0005))`
- `ck_hpt_paro_pos`: `CHECK ((horas_paro_total >= (0)::numeric))`
- `ck_hpt_ratios`: `CHECK ((((disponibilidad IS NULL) OR ((disponibilidad >= (0)::numeric) AND (disponibilidad <= (1)::numeric))) AND ((rendimiento IS NULL) OR (rendimiento >= (0)::numeric)) AND ((calidad_proxy IS NULL) OR ((calidad_proxy >= (0)::numeric) AND (calidad_proxy <= (1)::numeric)))))`

`dw.hecho_paro`

Tabla de hechos de eventos de paro.

Grano declarado. Un registro por evento de paro de un codigo concreto dentro de un turno de una maquina. Es el resultado de despivotar los 18 pares de columnas `<minutos, horas>` que el Excel tiene en horizontal. 16.482 filas.

Filas cargadas: aproximadamente 16.482.

Columna	Tipo	Clave	Descripcion, origen y regla
`paro_id`	`bigint NOT NULL`	PK	Llave primaria tecnica de la fila. ORIGEN: construida.
`fecha_key`	`integer NOT NULL`	FK → `dim_fecha`	Llave a dim_fecha. ORIGEN: columna 'Dia'.
`maquina_key`	`smallint NOT NULL`	FK → `dim_maquina`	Llave a dim_maquina. ORIGEN: columna 'Maquina'.
`turno_key`	`smallint NOT NULL`	FK → `dim_turno`	Llave a dim_turno. ORIGEN: columna 'Turno'.
`operario_key`	`integer NOT NULL`	FK → `dim_operario`	Llave a dim_operario. ORIGEN: columna 'Operario'. REGLA: pseudonimizado.
`referencia_key`	`integer NOT NULL`	FK → `dim_referencia`	Llave a dim_referencia. ORIGEN: columna 'Referencia'.
`paro_key`	`integer NOT NULL`	FK → `dim_paro`	Llave a dim_paro, es decir la causa del paro con sus cuatro niveles. ORIGEN: posicion del par de columnas mas la columna de subcodigo correspondiente. REGLA: si el subcodigo no viene especificado se asigna el miembro de relleno y se marca subcodigo_imputado.
`area_key`	`smallint`	FK → `dim_area_involucrada`	Llave a dim_area_involucrada. ORIGEN: columna 'Area involucrada'.
`personal_key`	`integer`	FK → `dim_personal_mantenimiento`	Llave a dim_personal_mantenimiento. ORIGEN: columna 'Personal de mantenimiento'. REGLA: pseudonimizado.
`produccion_turno_id`	`bigint`	FK → `hecho_produccion_turno`	Llave al turno de produccion al que pertenece el paro; NULL si no se pudo vincular. ORIGEN: construida. REGLA: 3.028 filas de la fuente son CONTINUACIONES generadas por el boton 'Ingreso subcodigo' y no traen pacas ni horas. Se vinculan a su cabecera en cascada de tres niveles: por fecha, maquina, operario, referencia y turno; luego sin turno; luego solo por fecha y maquina. Quedan 903 filas sin vincular, que suman 1,917 h, el 0,02% del tiempo de paro.
`fila_origen_excel`	`integer NOT NULL`		Numero de fila en la hoja 'Base De Datos' del Excel (la fila 10 es la primera con datos). ORIGEN: construida. REGLA: trazabilidad: permite volver a la celda exacta del Excel ante cualquier duda.
`observacion_paro`	`text`		Observacion libre escrita por mantenimiento. ORIGEN: columna 'Observacion del paro'. REGLA: se carga sin modificar; es texto libre y no se usa para clasificar, solo para consultar el caso concreto.
`minutos_paro`	`numeric(10,3) NOT NULL`		Duracion del paro en minutos, tal como la registra la fuente. ORIGEN: columna de minutos del par correspondiente al codigo. REGLA: se conserva el valor original, incluidos los decimales raros (219,6 y 160,5), para no perder trazabilidad.
`horas_paro`	`numeric(12,8) NOT NULL`		Duracion del paro en horas. ORIGEN: derivada. REGLA: minutos / 60, con ocho decimales para que la suma de 16.482 eventos no acumule error de redondeo frente al total que calcula el Excel.
`unidades_no_producidas`	`bigint`		Unidades que se dejaron de producir por este paro. ORIGEN: derivada. REGLA: tasa ideal por los minutos del paro.
`es_paro_planeado`	`boolean NOT NULL`		Verdadero si el codigo es de naturaleza planeada. ORIGEN: derivada de dim_paro. REGLA: se copia al hecho para que los filtros del tablero no tengan que pasar por la dimension. *(Valor por defecto: `false`.)*
`proviene_de_continuacion`	`boolean NOT NULL`		Verdadero si la fila venia de una continuacion del boton 'Ingreso subcodigo'. ORIGEN: derivada. REGLA: hace visible el artefacto del formulario de captura. *(Valor por defecto: `false`.)*

Columna	Tipo	Clave	Descripcion, origen y regla
`subcodigo_imputado`	`boolean NOT NULL`		Verdadero si la causa raiz no venia especificada. ORIGEN: derivada. REGLA: solo se evalua en los codigos 01, 03 y 05, los unicos con subcodigos; 107 de 3.691 eventos (2,9%) carecen de causa raiz utilizable. *(Valor por defecto: `false`.)*
`minutos_atipicos`	`boolean NOT NULL`		Verdadero si la duracion supera las 8 horas. ORIGEN: derivada. REGLA: bandera de calidad; 3 eventos, el mayor de 900 minutos en el codigo 10. *(Valor por defecto: `false`.)*
`ejecucion_id`	`bigint NOT NULL`		Identificador de la ejecucion del ETL que cargo la fila. ORIGEN: construida. REGLA: permite auditar y revertir una carga concreta.
`cargado_en`	`timestamp with time zone NOT NULL`		Marca de tiempo de la carga. ORIGEN: construida. REGLA: default now(). *(Valor por defecto: `now()`.)*

Restricciones de validacion (CHECK). Son las reglas de negocio que la base impide violar, de modo que un dato incoherente no puede entrar ni por error de programacion:

- `ck_hp_coher`: `CHECK ((abs((horas_paro - (minutos_paro / 60.0))) < 0.0005))`
- `ck_hp_min`: `CHECK ((minutos_paro > (0)::numeric))`

`dw.hecho_produccion_hora`

Tabla de hechos de telemetria horaria.

Grano declarado. Un registro por hora de reloj y maquina. Es el grano que entregaria un historiador de PLC/SCADA. Hoy lo alimenta el simulador; el ETL del Excel no escribe aqui porque la fuente historica no tiene grano horario.

Filas cargadas: aproximadamente 1.056.

Columna	Tipo	Clave	Descripcion, origen y regla
`produccion_hora_id`	`bigint NOT NULL`	PK	Llave primaria tecnica. ORIGEN: construida.
`instante`	`timestamp with time zone NOT NULL`	UQ	Marca de tiempo del inicio de la hora. ORIGEN: construida por el simulador. REGLA: timestamptz nativo, para que funcionen las macros $__timeFilter y $__timeGroup de Grafana.
`fecha_key`	`integer NOT NULL`	FK → `dim_fecha`	Llave a dim_fecha. ORIGEN: derivada de instante.
`hora_del_dia`	`smallint NOT NULL`		Hora del dia, 0 a 23. ORIGEN: derivada de instante.
`maquina_key`	`smallint NOT NULL`	FK → `dim_maquina` UQ	Llave a dim_maquina. ORIGEN: construida.
`turno_key`	`smallint NOT NULL`	FK → `dim_turno`	Llave a dim_turno. ORIGEN: derivada de la hora del dia.
`referencia_key`	`integer NOT NULL`	FK → `dim_referencia`	Llave a dim_referencia. ORIGEN: construida. REGLA: el simulador usa la referencia que cada linea corre con mas frecuencia en el historico.
`operario_key`	`integer NOT NULL`	FK → `dim_operario`	Llave a dim_operario. ORIGEN: construida. REGLA: el simulador usa el miembro 'Sin informar': no inventa personas reales.
`paro_key`	`integer`	FK → `dim_paro`	Llave a dim_paro; NULL si la hora no tuvo paro. ORIGEN: construida. REGLA: la causa se muestrea de la distribucion REAL de dw.hecho_paro ponderada por horas perdidas, de modo que el Pareto del tablero operativo se parece al historico.
`minutos_programados`	`numeric(6,2) NOT NULL`		Minutos programados de la hora, normalmente 60. ORIGEN: construida. *(Valor por defecto: `60`.)*
`minutos_paro`	`numeric(6,2) NOT NULL`		Minutos de paro de la hora. ORIGEN: construida. REGLA: proceso de Poisson calibrado para que la disponibilidad promedio converja a la que la maquina mostro en 2024. *(Valor por defecto: `0`.)*

Columna	Tipo	Clave	Descripcion, origen y regla
minutos_operativos	numeric(6,2) NOT NULL		Minutos efectivos de produccion. ORIGEN: derivada. *(Valor por defecto: `60`.)*
pacas_producidas	integer NOT NULL		Pacas producidas en la hora. ORIGEN: derivada. *(Valor por defecto: `0`.)*
unidades_producidas	integer NOT NULL		Unidades producidas en la hora. ORIGEN: construida. *(Valor por defecto: `0`.)*
unidades_rechazadas	integer NOT NULL		Unidades rechazadas en la hora. ORIGEN: construida. REGLA: esta columna NO tiene equivalente en el Excel, porque la fuente no mide defectos. Existe aqui porque un historiador de PLC SI puede medirlo, y con ella el componente Calidad del OEE deja de ser un proxy. *(Valor por defecto: `0`.)*
tasa_ideal_unid_min	numeric(8,3) NOT NULL		Tasa ideal aplicada. ORIGEN: dim_estandar.
unidades_posibles	integer NOT NULL		Unidades posibles en el tiempo operativo. ORIGEN: derivada. *(Valor por defecto: `0`.)*
disponibilidad	numeric(7,6) NOT NULL		Disponibilidad de la hora. ORIGEN: derivada.
rendimiento	numeric(7,6) NOT NULL		Rendimiento de la hora. ORIGEN: derivada.
calidad	numeric(7,6) NOT NULL		Calidad de la hora. ORIGEN: derivada. REGLA: aqui si es Calidad MEDIDA, no proxy, porque existen unidades rechazadas.
oee	numeric(7,6) NOT NULL		OEE de la hora, con los tres componentes. ORIGEN: derivada.
registrado_en	timestamp with time zone NOT NULL		Marca de tiempo de la insercion. ORIGEN: construida. REGLA: distinta de instante; permite medir la latencia entre el momento productivo y su registro. *(Valor por defecto: `now()`.)*

Restricciones de validacion (CHECK). Son las reglas de negocio que la base impide violar, de modo que un dato incoherente no puede entrar ni por error de programacion:

- `ck_hph_hora`: `CHECK (((hora_del_dia >= 0) AND (hora_del_dia <= 23)))`
- `ck_hph_min`: `CHECK (((minutos_paro >= (0)::numeric) AND (minutos_paro <= minutos_programados)))`
- `ck_hph_oper`: `CHECK ((abs((minutos_operativos - (minutos_programados - minutos_paro))) < 0.01))`

`dw.dim_fecha`

Dimension de calendario CONSTRUIDA POR EL EQUIPO. No existe en la fuente.

Filas cargadas: aproximadamente 1.826.

Columna	Tipo	Clave	Descripcion, origen y regla
fecha_key	integer NOT NULL	PK	Llave surrogada con formato AAAAMMDD, legible a simple vista. ORIGEN: construida. REGLA: entero en lugar de fecha para que los indices y los JOIN sean mas compactos, y para poder leer la llave sin consultar la dimension.
fecha	date NOT NULL	UQ	Fecha del calendario. ORIGEN: construida. REGLA: columna marcada como fecha del modelo en Power BI; es la que usan las funciones de inteligencia de tiempo de DAX.
anio	smallint NOT NULL		Ano del calendario. ORIGEN: construida.
trimestre	smallint NOT NULL		Numero de trimestre, 1 a 4. ORIGEN: construida.
nombre_trimestre	character varying(8) NOT NULL		Trimestre como texto, por ejemplo 'T1'. ORIGEN: construida.
mes	smallint NOT NULL		Numero de mes, 1 a 12. ORIGEN: construida. REGLA: ordena a nombre_mes, para que los meses no salgan en orden alfabetico.

Columna	Tipo	Clave	Descripcion, origen y regla
nombre_mes	character varying(12) NOT NULL		Nombre del mes en espanol. ORIGEN: construida. REGLA: generado en el ETL y no con to_char, para no depender de la configuracion regional del servidor.
nombre_mes_corto	character varying(4) NOT NULL		Abreviatura del mes, por ejemplo 'ene'. ORIGEN: construida.
anio_mes	integer NOT NULL		Periodo como entero AAAAMM. ORIGEN: construida. REGLA: sirve para ordenar y para las funciones de ventana que comparan periodos.
etiqueta_anio_mes	character varying(9) NOT NULL		Periodo legible, por ejemplo '2024-03'. ORIGEN: construida.
dia	smallint NOT NULL		Dia del mes. ORIGEN: construida.
dia_del_anio	smallint NOT NULL		Dia del ano, 1 a 366. ORIGEN: construida.
dia_semana_iso	smallint NOT NULL		Dia de la semana ISO: 1 lunes a 7 domingo. ORIGEN: construida. REGLA: se usa el estandar ISO y no el de PostgreSQL (0 domingo) para que la semana empiece en lunes, como en la planta.
nombre_dia	character varying(12) NOT NULL		Nombre del dia de la semana en espanol. ORIGEN: construida.
nombre_dia_corto	character varying(4) NOT NULL		Abreviatura del dia. ORIGEN: construida.
semana_iso	smallint NOT NULL		Numero de semana ISO. ORIGEN: construida.
anio_semana_iso	integer NOT NULL		Ano de la semana ISO. ORIGEN: construida. REGLA: puede diferir de anio en la primera y la ultima semana del ano; se guarda aparte para no partir semanas al agregar.
es_fin_semana	boolean NOT NULL		Verdadero en sabado y domingo. ORIGEN: construida.
es_festivo	boolean NOT NULL		Verdadero si es festivo en Colombia. ORIGEN: construida. REGLA: festivos fijos, mas los calculados desde el Domingo de Pascua con el algoritmo de Butcher, mas los trasladables al lunes siguiente segun la Ley 51 de 1983 (Ley Emiliani).
nombre_festivo	character varying(60)		Nombre del festivo; NULL si no es festivo. ORIGEN: construida.
es_dia_habil	boolean NOT NULL		Verdadero si no es fin de semana ni festivo. ORIGEN: construida. REGLA: permite separar la produccion de dia habil de la de festivo, que tiene costo de mano de obra distinto.
fecha_key_anio_ant	integer		fecha_key del mismo dia del ano anterior. ORIGEN: construida. REGLA: precalculada para que los comparativos interanuales en SQL sean un JOIN y no un calculo de fechas en cada consulta.
anio_mes_anio_ant	integer		anio_mes del mismo mes del ano anterior. ORIGEN: construida. REGLA: igual que la anterior, para comparativos mensuales.

Restricciones de validacion (CHECK). Son las reglas de negocio que la base impide violar, de modo que un dato incoherente no puede entrar ni por error de programacion:

- `ck_dim_fecha_key`: `CHECK ((fecha_key = (to_char((fecha)::timestamp with time zone, 'YYYYMMDD'::text))::integer))`
- `ck_dim_fecha_mes`: `CHECK (((mes >= 1) AND (mes <= 12)))`
- `ck_dim_fecha_trimestre`: `CHECK (((trimestre >= 1) AND (trimestre <= 4)))`

`dw.dim_maquina`

Dimension de las cuatro lineas de envasado.

Filas cargadas: aproximadamente 4.

Columna	Tipo	Clave	Descripcion, origen y regla
`maquina_key`	`smallint NOT NULL`	PK	Llave surrogada entera, generada por el ETL. ORIGEN: construida. REGLA: numeracion secuencial; el valor 0 se reserva al miembro 'no informado' para no usar NULL en las tablas de hechos.
`codigo_maquina`	`character varying(20) NOT NULL`	UQ	Codigo de la linea tal como lo escribe la fuente: Vinilos_1 a Vinilos_4. ORIGEN: columna 'Maquina' de la hoja Base De Datos. REGLA: se conserva el codigo original para poder conciliar contra el Excel.
`nombre_maquina`	`character varying(40) NOT NULL`		Nombre legible de la linea. ORIGEN: construida.
`numero_linea`	`smallint NOT NULL`		Numero de linea, 1 a 4. ORIGEN: construida. REGLA: extraido del codigo; ordena la presentacion.
`planta`	`character varying(30) NOT NULL`		Planta donde esta la linea. ORIGEN: construida. REGLA: valor unico por ahora; la columna existe para que el modelo admita una segunda planta sin rediseno. *(Valor por defecto: `'Planta Vinilos y Temperas'::character varying`.)*
`familia_producto`	`character varying(30) NOT NULL`		Familia de producto que envasa la linea. ORIGEN: construida. *(Valor por defecto: `'Vinilos y temperas'::character varying`.)*
`factor_produccion`	`numeric(5,3) NOT NULL`		Multiplicador de capacidad de la linea respecto de la de referencia: V1 1,100, V2 1,160, V3 y V4 1,000. ORIGEN: estaba ESCONDIDO dentro de una formula de texto de la hoja 'Tiempos', no en ninguna celda de datos. REGLA: se extrajo leyendo la formula; permite inferir el estandar de una linea a partir del de otra cuando el catalogo no trae el par maquina-referencia. *(Valor por defecto: `1.000`.)*
`grupo_capacidad`	`character varying(20) NOT NULL`		Agrupacion por capacidad relativa. ORIGEN: construida. REGLA: derivada del factor de produccion; agrupa lineas comparables entre si.
`es_activa`	`boolean NOT NULL`		Verdadero si la linea esta en operacion. ORIGEN: construida. *(Valor por defecto: `true`.)*

Restricciones de validacion (CHECK). Son las reglas de negocio que la base impide violar, de modo que un dato incoherente no puede entrar ni por error de programacion:

- `ck_dim_maquina_factor`: `CHECK (((factor_produccion > (0)::numeric) AND (factor_produccion <= (3)::numeric)))`

`dw.dim_turno`

Dimension de turnos de trabajo.

Filas cargadas: aproximadamente 8.

Columna	Tipo	Clave	Descripcion, origen y regla
`turno_key`	`smallint NOT NULL`	PK	Llave surrogada entera, generada por el ETL. ORIGEN: construida. REGLA: numeracion secuencial; el valor 0 se reserva al miembro 'no informado' para no usar NULL en las tablas de hechos.
`codigo_turno`	`character varying(30) NOT NULL`	UQ	Codigo corto del turno: T1, T2, T3, TE1, TE2, TE3, NA, DESC. ORIGEN: construida.
`nombre_turno`	`character varying(40) NOT NULL`		Nombre del turno con su horario. ORIGEN: columna 'Turno' de la hoja Base De Datos. REGLA: la fuente escribe el turno de varias formas ('6am-2pm', '6am-2pm (Turno 1)', 'Turno 1'); se resuelven todas al mismo miembro.
`etiqueta_fuente`	`character varying(40) NOT NULL`		Forma en que la fuente escribe el turno. ORIGEN: idem. REGLA: se conserva para auditar la resolucion de variantes.
`hora_inicio`	`time without time zone`		Hora de inicio del turno. ORIGEN: derivada del nombre.

Columna	Tipo	Clave	Descripcion, origen y regla
hora_fin	time without time zone		Hora de fin del turno. ORIGEN: derivada del nombre.
duracion_horas	numeric(4,2)		Duracion nominal del turno en horas. ORIGEN: derivada. REGLA: sirve para detectar registros cuyas horas trabajadas exceden la duracion del turno.
tipo_jornada	character varying(20) NOT NULL		'Ordinario', 'Extendido' o 'No aplica'. ORIGEN: construida. REGLA: separa los turnos de 8 horas de las jornadas extendidas, que tienen un patron de paros distinto.
es_nocturno	boolean NOT NULL		Verdadero en el turno de noche. ORIGEN: construida. REGLA: permite comprobar si el turno nocturno rinde distinto, que es una pregunta recurrente de produccion. *(Valor por defecto: `false`.)*
orden_presentacion	smallint NOT NULL		Orden cronologico de presentacion. ORIGEN: construida.
es_valido	boolean NOT NULL		Falso en los miembros de relleno 'No aplica' y 'Descanso'. ORIGEN: construida. *(Valor por defecto: `true`.)*

Restricciones de validacion (CHECK). Son las reglas de negocio que la base impide violar, de modo que un dato incoherente no puede entrar ni por error de programacion:

- `ck_dim_turno_dur`: `CHECK (((duracion_horas IS NULL) OR ((duracion_horas >= (0)::numeric) AND (duracion_horas <= (24)::numeric))))`

`dw.dim_referencia`

Dimension de productos envasados, depurada de erratas de digitacion.

Filas cargadas: aproximadamente 63.

Columna	Tipo	Clave	Descripcion, origen y regla
referencia_key	integer NOT NULL	PK	Llave surrogada entera, generada por el ETL. ORIGEN: construida. REGLA: numeracion secuencial; el valor 0 se reserva al miembro 'no informado' para no usar NULL en las tablas de hechos.
codigo_referencia	character varying(60) NOT NULL	UQ	Codigo normalizado de la referencia. ORIGEN: construida. REGLA: nombre sin tildes, en mayusculas y sin espacios; es la clave con que se consolidan las variantes de escritura.
nombre_referencia	character varying(60) NOT NULL		Nombre de la referencia, depurado. ORIGEN: columna 'Referencia' de la hoja Base De Datos. REGLA: la fuente trae 52 valores distintos con erratas de digitacion; se corrigieron tres confusiones de nombre ('Alocdor' por 'Alocolor', 'Stilo Kids' por 'Estilo Kids', 'Klips 15cc (12col)' por su forma con espacio) y se consolidaron en 63 miembros limpios.
linea_comercial	character varying(30) NOT NULL		Linea comercial del producto. ORIGEN: derivada del nombre. REGLA: se extrae con expresion regular el patron ' cc (col)'.
volumen_cc	numeric(6,1)		Volumen del envase en centimetros cubicos. ORIGEN: derivada del nombre de la referencia. REGLA: idem.
etiqueta_presentacion	character varying(20)		Presentacion legible, por ejemplo '22 cc, 6 colores'. ORIGEN: construida.
numero_colores	smallint		Numero de colores de la presentacion. ORIGEN: derivada del nombre, y confirmada con la columna '# colores' de la hoja Tablas Desplegables. REGLA: determina cuantas unidades caben en una paca, asi que es imprescindible para comparar produccion entre referencias.
display_por_paca	integer		Displays que contiene una paca. ORIGEN: columna 'Display' de la hoja Tablas Desplegables.
unidades_por_paca	integer		Unidades que contiene una paca. ORIGEN: columna 'Unidades * paca' de la hoja Tablas Desplegables. REGLA: es el factor que convierte las pacas del registro en unidades comparables. En la hoja de hechos este dato era inservible: las columnas 7 y 9 estan 100% vacias y la 8 se reutilizo para guardar el turno.
es_no_aplica	boolean NOT NULL		Verdadero en el miembro de relleno. ORIGEN: construida. *(Valor por defecto: `false`.)*
tiene_estandar	boolean NOT NULL		Verdadero si existe estandar de ingenieria para la referencia. ORIGEN: construida. *(Valor por defecto: `false`.)*

Columna	Tipo	Clave	Descripcion, origen y regla
`variantes_fuente`	`text`		Lista de las variantes de escritura que la fuente usaba para esta referencia. ORIGEN: construida. REGLA: se conserva para poder auditar la consolidacion y demostrar que no se perdio ningun valor.

Restricciones de validacion (CHECK). Son las reglas de negocio que la base impide violar, de modo que un dato incoherente no puede entrar ni por error de programacion:

- `ck_dim_ref_colores`: `CHECK (((numero_colores IS NULL) OR ((numero_colores >= 1) AND (numero_colores <= 24))))`

`dw.dim_estandar`

Dimension de estandares de ingenieria por par maquina-referencia, con historia SCD Tipo 2.

Filas cargadas: aproximadamente 137.

Columna	Tipo	Clave	Descripcion, origen y regla
`estandar_key`	`integer NOT NULL`	PK	Llave surrogada entera, generada por el ETL. ORIGEN: construida. REGLA: numeracion secuencial; el valor 0 se reserva al miembro 'no informado' para no usar NULL en las tablas de hechos.
`maquina_key`	`smallint NOT NULL`	FK → `dim_maquina` UQ	Llave a dim_maquina. ORIGEN: construida. REGLA: el estandar es especifico del par maquina-referencia, porque la misma referencia corre a distinta velocidad en cada linea.
`referencia_key`	`integer NOT NULL`	FK → `dim_referencia` UQ	Llave a dim_referencia. ORIGEN: construida.
`unidades_por_minuto`	`numeric(8,3) NOT NULL`		Tasa ideal de produccion: unidades que la linea debe envasar por minuto. ORIGEN: columna 'unidades *minuto' del bloque maquina x referencia de la hoja 'Tablas Desplegables'. REGLA: es el estandar de ingenieria y el denominador del Rendimiento del OEE. Es el dato que hacia falta para poder calcular OEE y que estaba en una hoja auxiliar, no en la hoja de hechos.
`unidades_por_paca`	`integer NOT NULL`		Unidades que contiene una paca de esta referencia. ORIGEN: columna 'Unidades * paca' de la hoja 'Tablas Desplegables'. REGLA: convierte las pacas que registra el operario en unidades comparables entre referencias de 6 y de 12 colores.
`pacas_meta_hora`	`numeric(8,3) NOT NULL`		Meta de pacas por hora derivada del estandar. ORIGEN: construida. REGLA: unidades_por_minuto * 60 / unidades_por_paca. Se expresa en pacas porque es la unidad en que piensa el operario.
`version`	`smallint NOT NULL`		Numero de version del estandar para el par maquina-referencia. ORIGEN: construida. REGLA: SCD Tipo 2; empieza en 1 y se incrementa en cada cambio del estandar. *(Valor por defecto: `1`.)*
`valido_desde`	`date NOT NULL`	UQ	Fecha desde la que rige esta version del estandar. ORIGEN: construida. REGLA: SCD Tipo 2.
`valido_hasta`	`date NOT NULL`		Fecha hasta la que rigio esta version; NULL si es la vigente. ORIGEN: construida. REGLA: SCD Tipo 2. *(Valor por defecto: `'9999-12-31'::date`.)*
`es_vigente`	`boolean NOT NULL`		Verdadero en la version actual del estandar. ORIGEN: construida. REGLA: SCD Tipo 2; un indice unico parcial garantiza que solo exista una version vigente por par maquina-referencia. *(Valor por defecto: `true`.)*
`origen_estandar`	`character varying(40) NOT NULL`		Como se obtuvo el estandar: 'Catalogo' si venia en Tablas Desplegables, 'Inferido' si se dedujo de otra linea ajustando por el factor de produccion, 'Sin estandar' si no fue posible. ORIGEN: construida. REGLA: hace explicito el nivel de confianza del dato; los turnos con 'Sin estandar' quedan fuera del calculo del Rendimiento.
`motivo_cambio`	`character varying(80)`		Razon del cambio de version del estandar. ORIGEN: construida. REGLA: texto libre para auditar el historial del SCD2.

Restricciones de validacion (CHECK). Son las reglas de negocio que la base impide violar, de modo que un dato incoherente no puede entrar ni por error de programacion:

- `ck_dim_estandar_tasa`: `CHECK ((unidades_por_minuto >= (0)::numeric))`
- `ck_dim_estandar_vig`: `CHECK ((valido_hasta >= valido_desde))`

`dw.dim_paro`

Dimension de causas de paro con jerarquia desbalanceada de cuatro niveles.

Filas cargadas: aproximadamente 65.

Columna	Tipo	Clave	Descripcion, origen y regla
`paro_key`	`integer NOT NULL`	PK	Llave surrogada entera, generada por el ETL. ORIGEN: construida. REGLA: numeracion secuencial; el valor 0 se reserva al miembro 'no informado' para no usar NULL en las tablas de hechos.
`area_impacto`	`character varying(40) NOT NULL`		NIVEL 1 de la jerarquia de paros: area responsable de la causa. ORIGEN: construida. REGLA: clasificacion de los 18 codigos de paro segun quien debe actuar (Mantenimiento, Produccion, Calidad, Logistica, Servicios generales).
`codigo_paro`	`character(2) NOT NULL`	UQ	Codigo de paro de dos digitos, '01' a '18'. ORIGEN: cabecera de los 18 pares de columnas de la hoja Base De Datos. REGLA: el codigo se deduce de la POSICION de la columna, no de su texto, porque los encabezados tienen variantes de escritura.
`codigo_paro_numero`	`smallint NOT NULL`		El codigo como entero, para ordenar. ORIGEN: construida.
`nombre_codigo_paro`	`character varying(90) NOT NULL`		Descripcion del codigo segun el procedimiento P-MTO-22. ORIGEN: documento P-MTO-22 V1, vigente desde el 14/05/2025. REGLA: se toma la descripcion oficial del procedimiento, no la del encabezado del Excel, que esta abreviada.
`etiqueta_codigo_paro`	`character varying(95) NOT NULL`		NIVEL 2 de la jerarquia: codigo y descripcion juntos, por ejemplo '[05] Ajuste operativo'. ORIGEN: construida. REGLA: es la etiqueta que se muestra en los tableros; incluir el numero permite cruzarla con el formato en papel que usa la planta.
`naturaleza_paro`	`character varying(20) NOT NULL`		'Planeado' o 'No planeado'. ORIGEN: construida. REGLA: se clasifican como planeados los codigos 04, 08, 15, 16, 17 y 18 (mantenimiento preventivo, capacitacion, cambio de insumos, aseo, pausa activa y afines). Es la separacion que distingue el tiempo perdido EVITABLE del que es parte normal de la operacion, y sin ella el OEE castiga a la planta por hacer lo correcto.
`es_imputable_mantenimiento`	`boolean NOT NULL`		Verdadero si el paro es responsabilidad del area de mantenimiento. ORIGEN: construida. REGLA: permite medir el desempeno de mantenimiento sin cargarle los paros de produccion o de logistica. *(Valor por defecto: `false`.)*
`codigo_sistema`	`character varying(20) NOT NULL`		Codigo del sistema fisico de la maquina. ORIGEN: construida. REGLA: ATRIBUTO CONFORMADO, lo mas importante de esta dimension. Se deduce del prefijo numerico del subcodigo y unifica las ramas 1.x (falla electromecanica), 3.x (servicios) y 5.x (ajuste operativo) en el sistema al que todas se refieren.
`nombre_sistema`	`character varying(70) NOT NULL`		NIVEL 3 de la jerarquia: nombre del sistema fisico, por ejemplo 'Sistema de dosificacion de pintura'. ORIGEN: construida. REGLA: el Excel NO puede responder 'que sistema me cuesta mas tiempo' porque las tres ramas viven en columnas separadas. Al unificarlas se descubrio que el sistema dosificador explica el 44,6% del tiempo perdido de los codigos 01/03/05 (992 de 2.222,8 h), el 11,8% del tiempo perdido total.
`codigo_subcodigo`	`character varying(12) NOT NULL`	UQ	Codigo del subcodigo de causa raiz. ORIGEN: columnas 'Subcodigo N' de la hoja Base De Datos y hoja oculta 'Base de datos de Sub codigos'. REGLA: la fuente tiene DOS taxonomias conviviendo; la rama 4.x historica se mapea a la 5.x vigente (4.1 a 5.1, 4.2 a 5.2, 4.3 a 5.3, 4.4 a 5.5, 4.5 a 5.6, 4.6 a 5.7, 4.7 a 5.8, 4.8 a 5.9) y se corrige la errata del propio catalogo (1.4.3 debia ser 1.4.C).
`nombre_subcodigo`	`character varying(90) NOT NULL`		NIVEL 4 de la jerarquia: causa raiz concreta. ORIGEN: idem. REGLA: la fuente trae 45 variantes de escritura para unos 25 subcodigos del codigo 01; se resuelven confiando en el PREFIJO NUMERICO y no en el texto, que es el dato fiable.
`nivel_detalle`	`smallint NOT NULL`		Profundidad real del miembro en la jerarquia, 2 a 4. ORIGEN: construida. REGLA: la jerarquia es DESBALANCEADA (ragged): solo los codigos 01, 03 y 05 tienen subcodigos. Esta columna dice hasta donde se puede bajar en cada rama.
`admite_subcodigo`	`boolean NOT NULL`		Verdadero en los codigos 01, 03 y 05. ORIGEN: construida. REGLA: evita medir como 'dato incompleto' la ausencia de subcodigo en los 15 codigos que no lo tienen; sin esta distincion el indicador de completitud daria un 78% de falsos positivos. *(Valor por defecto: `false`.)*
`es_subcodigo_especificado`	`boolean NOT NULL`		Falso en los miembros de relleno 'N/A' y 'SIN-ESP'. ORIGEN: construida. REGLA: la jerarquia desbalanceada se resuelve con miembros de relleno EXPLICITOS en lugar de NULL, de modo que el drill-down del tablero nunca aterriza en un hueco. *(Valor por defecto: `false`.)*
`orden_presentacion`	`integer NOT NULL`		Orden de presentacion del miembro. ORIGEN: construida.

Restricciones de validacion (CHECK). Son las reglas de negocio que la base impide violar, de modo que un dato incoherente no puede entrar ni por error de programacion:

- `ck_dim_paro_nat`: `CHECK (((naturaleza_paro)::text = ANY ((ARRAY['No planeado'::character varying, 'Planeado'::character varying])::text[])))`
- `ck_dim_paro_nivel`: `CHECK ((nivel_detalle = ANY (ARRAY[2, 4])))`
- `ck_dim_paro_num`: `CHECK (((codigo_paro_numero >= 1) AND (codigo_paro_numero <= 18)))`

`dw.dim_tipo_paro_cabecera`

Dimension del tipo de paro declarado en la cabecera del registro.

Filas cargadas: aproximadamente 13.

Columna	Tipo	Clave	Descripcion, origen y regla
`tipo_paro_key`	`smallint NOT NULL`	PK	Llave surrogada entera, generada por el ETL. ORIGEN: construida. REGLA: numeracion secuencial; el valor 0 se reserva al miembro 'no informado' para no usar NULL en las tablas de hechos.
`codigo_tipo`	`character varying(20) NOT NULL`	UQ	Codigo corto del tipo de paro de cabecera. ORIGEN: construida.
`nombre_tipo`	`character varying(80) NOT NULL`		Tipo de paro declarado en la cabecera del registro. ORIGEN: columna 'Tipo de paro' de la hoja Base De Datos. REGLA: la fuente trae 19 variantes de escritura de DOS taxonomias distintas para unos 13 conceptos; se consolidaron en 13 miembros.
`grupo_tipo`	`character varying(40) NOT NULL`		Agrupacion de alto nivel del tipo de paro. ORIGEN: construida.
`taxonomia_origen`	`character varying(20) NOT NULL`		De cual de las dos taxonomias de la fuente proviene el miembro. ORIGEN: construida. REGLA: documenta la convivencia de taxonomias; permite medir cuanto del historico usa la nomenclatura antigua.
`variantes_fuente`	`text`		Variantes de escritura consolidadas en este miembro. ORIGEN: construida. REGLA: trazabilidad de la consolidacion.

`dw.dim_area_involucrada`

Dimension de areas de la empresa que intervienen en un paro.

Filas cargadas: aproximadamente 7.

Columna	Tipo	Clave	Descripcion, origen y regla
`area_key`	`smallint NOT NULL`	PK	Llave surrogada entera, generada por el ETL. ORIGEN: construida. REGLA: numeracion secuencial; el valor 0 se reserva al miembro 'no informado' para no usar NULL en las tablas de hechos.
`codigo_area`	`character varying(40) NOT NULL`	UQ	Codigo corto del area. ORIGEN: construida. REGLA: derivado del nombre, sin tildes ni espacios.
`nombre_area`	`character varying(60) NOT NULL`		Area de la empresa que atendio el paro. ORIGEN: columna 'Area involucrada' de la hoja Base De Datos. REGLA: se normalizo capitalizacion y se consolidaron variantes de escritura en 7 miembros.
`es_area_soporte`	`boolean NOT NULL`		Verdadero si el area es de soporte (mantenimiento, calidad, laboratorio) y no de produccion. ORIGEN: construida. REGLA: clasificacion manual del equipo, usada para separar la responsabilidad del paro. *(Valor por defecto: `false`.)*

`dw.dim_operario`

Dimension de personal de envasado, PSEUDONIMIZADA.

Filas cargadas: aproximadamente 44.

Columna	Tipo	Clave	Descripcion, origen y regla
operario_key	integer NOT NULL	PK	Llave surrogada entera, generada por el ETL. ORIGEN: construida. REGLA: numeracion secuencial; el valor 0 se reserva al miembro 'no informado' para no usar NULL en las tablas de hechos.
codigo_operario	character varying(16) NOT NULL	UQ	Codigo pseudonimo estable, formato OPER-NNN. ORIGEN: construida. REGLA: se asigna por orden de aparicion; es estable entre ejecuciones del ETL.
alias_operario	character varying(30) NOT NULL		Alias que se muestra en los tableros, formato 'Operario NNN'. ORIGEN: construida. REGLA: PSEUDONIMIZACION. Es el unico identificador que sale del esquema dw; el nombre real nunca llega a los tableros.
rol	character varying(30) NOT NULL		Rol del trabajador. ORIGEN: construida. *(Valor por defecto:* `'Operario de envasado'::character varying`*.)*
es_identificado	boolean NOT NULL		Falso en el miembro 'Sin informar'. ORIGEN: construida. REGLA: la fuente trae 'No' y 'No aplica' como marcadores de ausencia; se consolidan en un unico miembro de relleno con llave 0. *(Valor por defecto:* `true`*.)*
primera_aparicion	date		Primera fecha en que aparece el operario. ORIGEN: derivada de la hoja Base De Datos. REGLA: min(fecha) de sus registros.
ultima_aparicion	date		Ultima fecha en que aparece. ORIGEN: derivada. REGLA: max(fecha) de sus registros.
turnos_registrados	integer NOT NULL		Numero de turnos en que aparece. ORIGEN: derivada. REGLA: conteo de registros; sirve para distinguir al personal de planta del eventual. *(Valor por defecto:* `0`*.)*

`dw.dim_personal_mantenimiento`

Dimension de personal de mantenimiento, PSEUDONIMIZADA.

Filas cargadas: aproximadamente 39.

Columna	Tipo	Clave	Descripcion, origen y regla
personal_key	integer NOT NULL	PK	Llave surrogada entera, generada por el ETL. ORIGEN: construida. REGLA: numeracion secuencial; el valor 0 se reserva al miembro 'no informado' para no usar NULL en las tablas de hechos.
codigo_personal	character varying(16) NOT NULL	UQ	Codigo pseudonimo estable, formato TEC-NNN. ORIGEN: construida.
alias_personal	character varying(30) NOT NULL		Alias mostrado en los tableros, formato 'Tecnico NNN'. ORIGEN: construida. REGLA: PSEUDONIMIZACION, igual que en dim_operario.
area	character varying(40) NOT NULL		Area del tecnico. ORIGEN: derivada de la fuente. REGLA: normalizada. *(Valor por defecto:* `'Mantenimiento'::character varying`*.)*
es_identificado	boolean NOT NULL		Falso en el miembro 'Sin informar'. ORIGEN: construida. *(Valor por defecto:* `true`*.)*

6 ETL, calidad de datos y conciliación

Los informes con las cifras exactas los **genera el propio ETL** en cada ejecución:

- `etl/salida/informe_calidad_datos.md` — las 21 reglas con conteos antes y después.
- `etl/salida/informe_conciliacion.md` — las 62 pruebas de conciliación.
- `etl/salida/resumen_etl.json` — resumen para consumo automático.

Este documento explica **las decisiones**: por qué esta herramienta, qué reglas se aplicaron y qué significan, y cómo se demuestra que lo cargado concuerda con la fuente.

---

1. Justificación de la herramienta: Python con `openpyxl` y `psycopg`

La herramienta es libre, así que hay que justificarla. Se evaluaron tres opciones.

1.1. Lo que se descartó

Power Query / Dataflows. Es la opción natural en un entorno Microsoft y resuelve bien el despivote. Se descartó porque:

- El código M **no es legible en un diff de git**. Queda embebido en el artefacto de Power BI y revisar un cambio exige abrir la herramienta. El enunciado pide ETL versionado y reproducible.
- **No puede escribir en PostgreSQL.** Power Query lee y transforma, pero el destino es el modelo de Power BI. Se necesitaría un segundo mecanismo para materializar el almacén, y entonces el almacén dejaría de ser la única fuente de verdad para Grafana.
- **No admite pruebas automáticas.** Las reglas de resolución de subcódigos —45 variantes de escritura y dos taxonomías— son lógica de negocio que necesita pruebas unitarias.

SQL puro con `COPY` del Excel a staging. Tentador por lo directo, pero:

- PostgreSQL no lee `.xlsm`. Haría falta un paso previo de conversión, así que no se evita el lenguaje de programación, solo se parte el proceso en dos.
- El cálculo del Domingo de Pascua (algoritmo de Butcher) y los festivos trasladables de la Ley 51 de 1983 son procedimentales. En SQL serían ilegibles.
- La normalización difusa de 45 variantes de texto con expresiones regulares en SQL es frágil y difícil de probar.

1.2. Por qué Python

- **`openpyxl` lee `.xlsm` directamente**, incluidas las hojas ocultas, y con `data_only=True` toma el **valor calculado** de las fórmulas, que es lo que hace falta para conciliar contra las tablas dinámicas. Con `read_only=True` recorre 8.208 filas sin cargar el libro entero en memoria.
- **El código es revisable.** Cada regla de limpieza es una función con nombre, y el `git diff` de un cambio de criterio se lee en el navegador.
- **`psycopg` 3 con `COPY`** carga por flujo binario, no con `INSERT` fila a fila: el ETL completo tarda **4 segundos**.
- **Transacción única con rollback.** Si una regla bloqueante falla, no queda nada a medio cargar. El almacén está completo y conciliado, o está como estaba.
- **Se prueba.** Las tablas de resolución de turnos, referencias y subcódigos tienen pruebas unitarias; son el corazón de la limpieza.
- **Dependencias mínimas**: tres paquetes (`openpyxl`, `psycopg[binary]`, `python-dateutil`), con versión fijada. El contenedor se reconstruye igual dentro de un año.

1.3. Arquitectura del ETL en seis fases

```
1. EXTRACCIÓN     Excel → stg.*  (todo como TEXT, sin rechazar ninguna fila)
2. DIMENSIONES    stg.* → dw.dim_*  (normalización y pseudonimización)
3. HECHOS         stg.* → dw.hecho_*  (despivote y cálculo de OEE)
4. CALIDAD        21 reglas con conteos antes/después → aud.regla_calidad
5. CONCILIACIÓN   62 pruebas contra la fuente → aud.conciliacion
6. CIERRE         informes en Markdown y JSON + registro en aud.ejecucion_etl
```

La zona de aterrizaje (`stg`) guarda todo como `TEXT`. Es deliberado: si staging tuviera tipos, una fila con «32» horas o una fecha mal escrita haría fallar la extracción y se perdería la evidencia del problema. Cargando texto, **todo entra** y los problemas se detectan y se cuentan en la fase 4, donde se pueden documentar.

---

2. Reglas de limpieza y su efecto

Las 21 reglas se registran en `aud.regla_calidad` con **conteos antes, afectadas y después**, severidad y resultado. Las dos marcadas como `BLOQUEANTE` (DQ-18, coherencia interna del OEE; DQ-19, integridad referencial de los paros) **abortan la carga** si fallan: en la última ejecución ambas dieron 0 inconsistencias.

2.1. Las reglas que cambian el número de filas

Regla	Qué hace	Antes	Afectadas	Después
DQ-01	Descarta 42 duplicados exactos	8.208	42	8.166
DQ-02	Separa las filas de continuación, que no son registros de producción	8.208	3.028	5.138
DQ-03	Vincula los paros de continuación a su turno cabecera	3.028	903 sin vincular	2.125 vinculados
DQ-17	**No carga** la hoja oculta de subcódigos	1.252	1.252	0

DQ-01. Los 42 duplicados aportan 129 h, 1.019 pacas y 18,116667 h de paro. Se conserva la primera ocurrencia por `hash_fila`. El efecto sobre el informe del comité se cuantifica en la conciliación (bloque 3).

DQ-02. Es la regla de mayor impacto conceptual: el **37 % de las filas de la «base de datos» no son registros de producción**. Quien cuente filas para medir cualquier cosa se equivoca en un tercio.

DQ-03. La vinculación es en cascada de tres niveles: por fecha, máquina, operario, referencia y turno (2.063 filas); luego sin turno (11); luego solo por fecha y máquina (51), eligiendo el turno con más horas programadas. Quedan **903 filas sin vincular**, de las cuales solo **5 traen minutos de paro**: suman **1,9167 h, el 0,0227 % del tiempo de paro**. Esas horas **sí** entran al total y al Pareto; lo único que no se puede es atribuirlas a un turno concreto.

> La cascada se aplica dos veces: en Python, para repartir el tiempo de paro entre los turnos, y en SQL, para resolver la llave foránea `hecho_paro → hecho_produccion_turno`. Las dos implementaciones **deben cubrir los mismos tres niveles**. Mientras la de SQL cubría solo los dos primeros, 53,57 h de paro quedaban en el detalle sin llave foránea aunque sus horas ya estuvieran sumadas en el agregado del turno. Hoy el detalle con llave (8.429,6183 h) y el agregado de `horas_paro_total` (8.429,6184 h) coinciden, y esa igualdad es lo que vigila la prueba de conciliación B2.

DQ-17. La hoja oculta `Base de datos de Sub codigos` tiene 1.252 filas, de las cuales **982 ya están** en `Base De Datos`. Cargarla duplicaría 679,2 h de paro. Las 270 ausentes no tienen minutos, así que no aportan nada. **No se carga**, y la decisión queda documentada en lugar de ser una omisión silenciosa.

2.2. Las reglas que normalizan sin descartar

Regla	Qué normaliza	Afectadas
DQ-08	Erratas de digitación en referencias (52 valores → 63 miembros limpios)	3 confusiones de nombre
DQ-10	Dos taxonomías de subcódigos (`4.x` histórica → `5.x` vigente) y la errata del catálogo (`1.4.3` → `1.4.C`)	475 filas de la rama antigua
DQ-16	Columna «Tipo de paro»: 19 variantes de dos taxonomías → 13 miembros	2.184

La regla de oro en DQ-10: **confiar en el prefijo numérico y no en el texto**. El número es el dato fiable; el texto es lo que cada persona escribió ese día.

2.3. Las reglas que marcan sin modificar

Estas no cambian el dato: le ponen una bandera para que el tablero pueda excluirlo y el auditor pueda encontrarlo.

Regla	Qué marca	Afectadas
DQ-05	Turno imputado porque la fuente no lo traía	2.409 de 5.138

Regla	Qué marca	Afectadas
DQ-06	Operario no informado	2.620
DQ-07	Referencia no informada	2.390
DQ-09	Causa raíz sin especificar, **solo** en los códigos 01, 03 y 05	107 de 3.691 (2,9 %)
DQ-11	Paro mayor que las horas trabajadas (el peor: 18,17 h en un turno de 10,5)	9
DQ-12	Horas trabajadas fuera del rango plausible de un turno, más de 12 h (una fila declara 16 h)	1
DQ-13	Duración atípica (> 8 h; la mayor de 900 min en el código 10)	3
DQ-14	Sin estándar de ingeniería, luego sin Rendimiento	2.686 de 5.138
DQ-21	**Rendimiento implausible**: el caso extremo declara un 1.561 %, es decir 16× el máximo teórico	22 de 2.452

DQ-09 merece una nota, porque medirla mal es fácil. El denominador son **solo** los eventos de los códigos 01, 03 y 05, los únicos con árbol de subcódigos. Medida sobre los 18 códigos daría un 78 % de registros «incompletos», cuando la ausencia de subcódigo en los otros 15 no es un defecto sino que el nivel no existe.

DQ-21 es un hallazgo de la carga, no un error del ETL. 22 turnos declaran una producción superior al 150 % del máximo que permite el estándar; el peor, un 1.561 %, es decir 16 veces. No es una línea excepcional: o las pacas se digitaron mal, o las horas quedaron subregistradas, o el estándar está obsoleto. Se **conserva** el valor para poder auditarlo y se **excluye** del indicador agregado, del índice parcial y de las medidas DAX.

2.4. Las reglas que solo documentan

Regla	Qué documenta
DQ-04	Las tres columnas que deberían convertir pacas a unidades son inservibles: las 7 y 9 están 100 % vacías y la 8 se reutilizó para guardar el turno en 687 filas
DQ-15	«Horas no trabajadas» **no es tiempo de paro**: 1.263 filas traen un 24 fijo y la suma (41.519,85 h) supera las horas trabajadas
DQ-20	La fuente **no mide unidades defectuosas**: el componente Calidad del OEE no es medible y se usa un proxy declarado

DQ-15 y DQ-20 no modifican nada, y son de las más importantes. Marcan los dos errores de interpretación que habrían invalidado el proyecto entero: sumar las horas no trabajadas como paro, y presentar un componente de Calidad como si estuviera medido.

---

3. Conciliación con la fuente

El enunciado pide «demostrar que los totales cargados concuerdan con la fuente, o explicar y justificar las diferencias». Hay una tensión real que obliga a separar dos preguntas:

> El Excel contiene 42 duplicados exactos. Las tablas dinámicas que la empresa lleva al comité **los incluyen**, porque una tabla dinámica suma lo que encuentra. El modelo dimensional **los descarta**, porque cargar dos veces el mismo turno sería un error. Luego los totales **no pueden** coincidir, y eso no es un fallo: es la limpieza funcionando.

Por eso la conciliación se hizo en **cuatro bloques**, con **62 pruebas**: 58 OK, 4 informativas y **0 fallidas**.

Bloque 1 — ¿El modelo entiende el negocio igual que el Excel?

35 pruebas, todas OK. Se recalculan los indicadores **desde staging incluyendo los duplicados**, es decir imitando exactamente lo que hace una tabla dinámica, y se comparan contra las cifras del Excel con tolerancia de $\mathbf{1 \times 10^{-6}}$.

Qué se contrasta	Resultado
`TD_prodMaq`: % Productividad de Vinilos_2 en 2024, mes a mes y total	13 de 13 coinciden a 6 decimales (total: 0,624722)
`Hoja4`: horas trabajadas por máquina en 2023	4 de 4 exactas (V1 3.390,0 · V2 1.220,5 · V3 4.221,3 · V4 4.002,55)

Qué se contrasta	Resultado
`TD_prodCodigo`: participación de los 18 códigos de paro	18 de 18 coinciden a 6 decimales

Esto es lo que demuestra que la interpretación es correcta. Si la fórmula del modelo reproduce la del Excel hasta el sexto decimal, cualquier diferencia posterior viene de la limpieza y no de haber entendido mal el negocio. Es también la prueba de que el «% Productividad» del Excel **es** la Disponibilidad del OEE.

Bloque 2 — ¿Se cargó todo, sin perder ni duplicar nada?

5 pruebas, todas OK. Fuente **depurada** (menos el aporte de los 42 duplicados) contra los totales del modelo.

Prueba	Fuente depurada	Modelo	Diferencia
Horas trabajadas	37.934,35	37.934,35	0
Pacas producidas	377.759	377.759	0
Tiempo de paro (despivote)	8.431,5350	8.431,5350	0,000004 h
Paro atribuido a turnos	8.429,6183	8.429,6184	0,00005 h
Trazabilidad de filas	8.208	8.208	0

Dos pruebas merecen comentario:

El despivote. La fuente trae el total de paro en una columna calculada por fila; el modelo lo **reconstruye** sumando los 18 pares desplegados en 16.482 eventos. Coincidir demuestra que no se perdió ni se duplicó un minuto. La diferencia de 0,000004 h son **14 milisegundos sobre 8.431 horas**, redondeo acumulado de 16.482 divisiones por 60.

La trazabilidad de filas. `8.208 = 5.138 turnos + 3.028 continuaciones + 42 duplicados`. **Ninguna fila de la fuente queda sin explicación**, y es la prueba que cierra el argumento de que no se perdió nada por el camino.

Bloque 3 — ¿Cuánto se equivoca hoy el informe del comité?

4 pruebas informativas. No hacen fallar el ETL: cuantifican un hallazgo.

Cifra	Informe actual	Valor correcto	Inflación
Horas trabajadas	38.063,35	37.934,35	**+129 h** (+0,34 %)
Pacas producidas	378.778	377.759	**+1.019** (+0,27 %)
Tiempo de paro	8.449,65	8.431,54	**+18,12 h** (+0,21 %)
% Productividad V2 2024	0,624722	0,624851	−1,3 puntos básicos

El efecto sobre el **ratio** es pequeño, porque los duplicados afectan numerador y denominador a la vez. Lo relevante no es la magnitud: es que el indicador que sustenta decisiones de inversión se calcula hoy sobre un conjunto con duplicados que nadie había detectado, y que **el formulario no tiene ningún control que lo impida**.

Bloque 4 — ¿Es exacto el despivote, código por código?

18 pruebas, todas OK. Fuente depurada contra `hecho_paro`, código a código. La mayor diferencia es de **0,0036 h (13 segundos)** en el código 16, que es el de más eventos (2.971), y es redondeo acumulado.

Por qué cuatro bloques y no uno

Porque responden preguntas distintas y mezclarlas produce una conciliación que no significa nada. Si solo se comparara contra el Excel bruto, el ETL fallaría 21 pruebas y la conclusión sería «el modelo está mal». Si solo se comparara contra la fuente depurada, se perdería la demostración de que la fórmula es equivalente, **y nadie se enteraría de que el informe del comité está inflado**. El bloque 1 prueba la lógica, el 2 prueba la carga, el 3 convierte la diferencia en un hallazgo accionable y el 4 prueba la transformación más delicada.

---

4. Reproducibilidad

El proceso completo se reproduce desde cero con **un solo comando**:

```
docker compose up -d --build
```

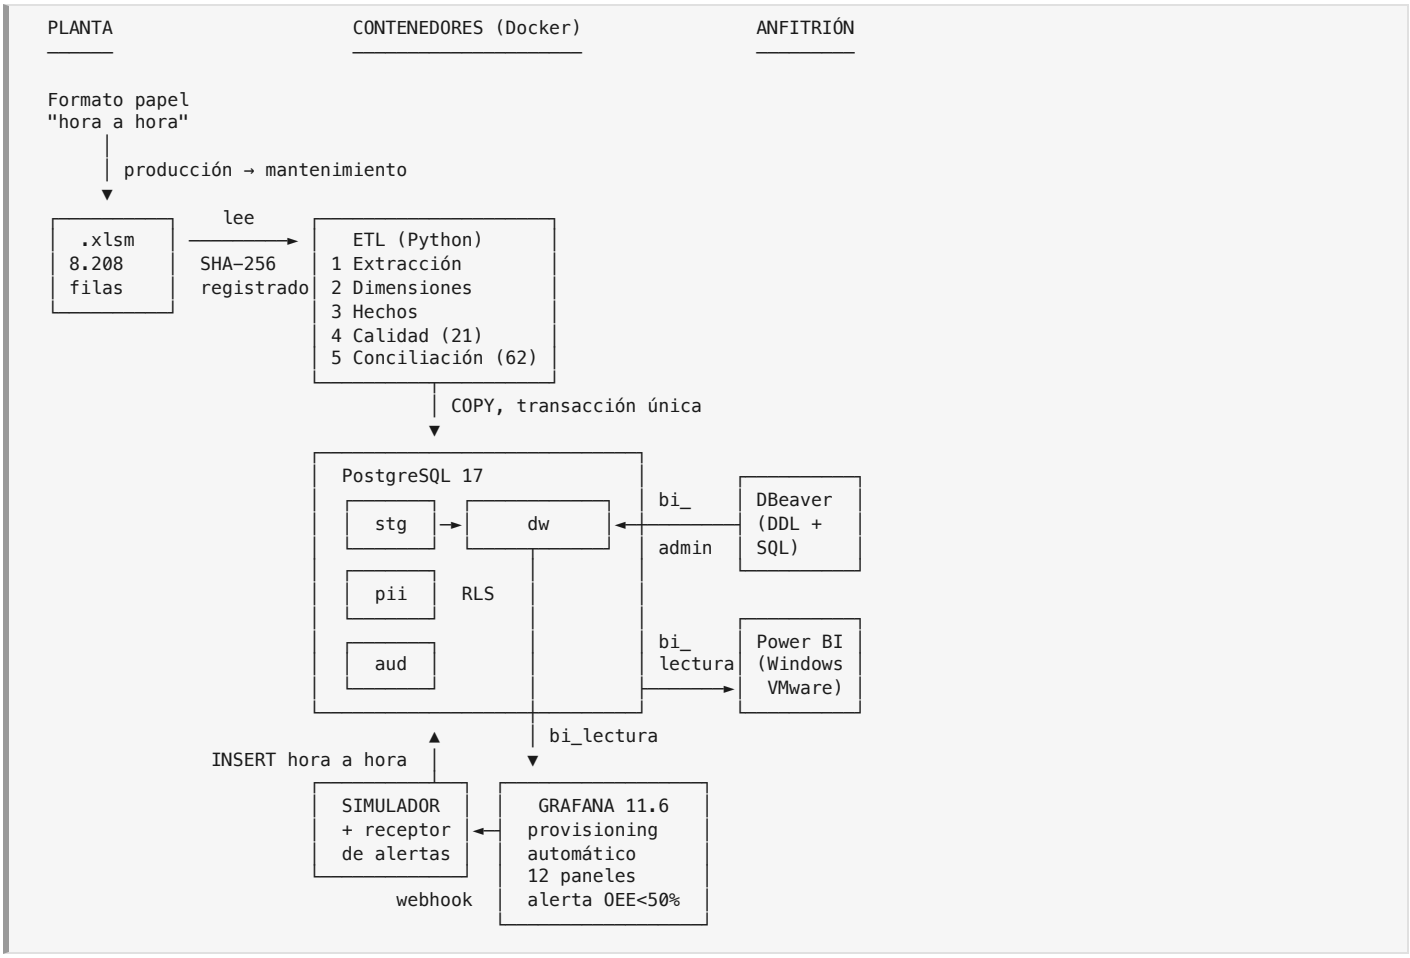
Verificado: con los volúmenes eliminados, la pila entera —PostgreSQL, DDL, ETL, Grafana con su provisioning y el simulador— queda operativa en **12 segundos**, y el ETL termina con código de salida 0 y resultados idénticos a la ejecución anterior (58 pruebas OK, 0 fallidas). El detalle está en el README.

Lo que garantiza la reproducibilidad:

- **Versiones fijadas** en las imágenes (`postgres:17-alpine`, `grafana/grafana:11.6.0`, `python:3.12-slim`) y en las dependencias de Python.
- **SHA-256 del Excel** registrado en `aud.ejecucion_etl`: si la fuente cambia, queda constancia de que las cifras se calcularon sobre otro archivo.
- **`ejecucion_id` en cada fila de hechos**, para poder auditar o revertir una carga concreta.
- **Transacción única**: no hay estados intermedios.

7 Arquitectura de la solución

1. Diagrama



---

2. Las cuatro capas y por qué están separadas

Capa 1 · Origen

El Excel **se lee, nunca se escribe**. El ETL registra su **SHA-256** en `aud.ejecucion_etl`, de modo que si la fuente cambia queda constancia de que las cifras se calcularon sobre otro archivo. La copia de trabajo vive en `datos/fuente/`.

Capa 2 · Almacén: cuatro esquemas con responsabilidades distintas

Esquema	Contiene	Quién puede leerlo
`stg`	Zona de aterrizaje, **todo como `TEXT`**	Solo `bi_admin`
`dw`	El modelo dimensional	`bi_admin` y `bi_lectura`
`pii`	Nombres reales de operarios y personal, con **RLS**	Solo el rol `pii_reidentificacion`
`aud`	Calidad, conciliación y registro de ejecuciones	`bi_admin` y `bi_lectura`

La separación no es organizativa, es **el mecanismo de seguridad**: los tableros se conectan con `bi_lectura`, que tiene `SELECT` únicamente en `dw` y `aud`. Está comprobado que ese rol **no puede** leer `pii` ni `stg`, ni escribir en `dw` (ver 10-datos-personales-y-seguridad.md).

Que `aud` sea legible por los tableros es intencional: permite publicar el indicador de completitud del registro junto a los indicadores de negocio, para que quien lea un número sepa de qué calidad de dato viene.

Capa 3 · Transformación

El ETL corre **una vez, al arrancar la pila**, y termina. No es un servicio: `restart: "no"` y Grafana espera a que haya finalizado con éxito (`service_completed_successfully`) para no mostrar nunca un tablero vacío.

Capa 4 · Consumo

Dos capas con propósitos distintos, detallado en 08-powerbi-vs-grafana.md:

- **Grafana** en el contenedor, conectado a `dw` para el tablero operativo.
- **Power BI** en el anfitrión (Windows sobre VMware), conectado a `dw` para el tablero analítico. **No lee el Excel**: lee la base de datos.
- **DBeaver** en el anfitrión, para administrar el DDL y ejecutar las consultas analíticas.

---

3. Decisiones de la contenerización

3.1. Un solo comando

```
docker compose up -d --build
```

Los scripts de DDL están montados en `/docker-entrypoint-initdb.d`, que la imagen de PostgreSQL ejecuta en orden alfabético al crear el volumen de datos: `00_roles_y_esquemas` → `10_ddl_staging` → `20_ddl_dimensiones` → `30_ddl_hechos` → `40_indices_y_restricciones` → `50_vistas_analiticas` → `60_permisos` → `70_diccionario`.

3.2. Orden de arranque garantizado con `healthcheck`

```
postgres:
  healthcheck:
    test: ["CMD-SHELL", "pg_isready -U $POSTGRES_USER -d $POSTGRES_DB"]
etl:
  depends_on:
    postgres: { condition: service_healthy }
grafana:
  depends_on:
    etl: { condition: service_completed_successfully }
```

`depends_on` sin condición solo espera a que el contenedor **arranque**, no a que el servicio esté **listo**: el ETL fallaría intentando conectarse a una base que todavía está inicializándose. Con `service_healthy` espera a que `pg_isready` responda, y con `service_completed_successfully` Grafana espera a que el ETL **termine bien**.

3.3. Persistencia por volúmenes nombrados

```
volumes:
  pgdata:      { name: bioee-pgdata }
  grafana-data:{ name: bioee-grafana-data }
```

Volúmenes **nombrados** y no *bind mounts* a carpetas del anfitrión, por dos razones:

- El rendimiento de E/S de un bind mount en macOS es notablemente peor.
- Los datos de PostgreSQL son archivos internos del motor: no tienen por qué estar en el árbol del proyecto, y si estuvieran acabarían en el repositorio por descuido.

`docker compose down` conserva los datos; `down -v` los borra y fuerza una reconstrucción completa, que es precisamente la prueba de reproducibilidad.

> **Nota de implementación, encontrada por las malas:** el proyecto vive en `~/Developer` y **no** en iCloud Drive, porque Docker en macOS no puede montar rutas de iCloud (falla con `Operation not permitted` al leer `/docker-entrypoint-initdb.d/`). Además, un repositorio git dentro de iCloud se corrompe por la sincronización.

3.4. Credenciales por variables de entorno

Ningún archivo del repositorio contiene una contraseña ni una cadena de conexión con contraseña. `docker-compose.yml` referencia `${POSTGRES_PASSWORD}` y similares; los valores viven en `.env`, que está **excluido** por `.gitignore`. Se versiona `.env.example` con los nombres de las variables y comentarios sobre qué poner en cada una.

Un bloque YAML reutilizable evita repetir la configuración en cada servicio:

```
x-db-env: &db-env
  PGHOST: postgres
  PGDATABASE: ${POSTGRES_DB}
  PGUSER: ${POSTGRES_USER}
  PGPASSWORD: ${POSTGRES_PASSWORD}
```

3.5. Provisioning de Grafana: cero configuración manual

Es el requisito que distingue a quien entendió Docker, y se resuelve con tres archivos montados en `/etc/grafana/provisioning`:

Archivo	Qué carga
`datasources/postgres.yml`	La conexión a PostgreSQL con el rol `bi_lectura`; la contraseña se interpola desde la variable de entorno
`dashboards/tableros.yml`	El proveedor que lee los JSON del repositorio, con `allowUiUpdates: false`
`alerting/alertas.yml`	La regla de alerta, el punto de contacto y la política de notificación

`allowUiUpdates: false` es deliberado: **el tablero del repositorio es la única verdad**. Nadie puede editarlo desde la interfaz y dejar el repositorio desactualizado; para cambiarlo hay que editar el JSON y versionarlo, que es el objetivo del control de versiones.

3.6. Qué corre en el contenedor y qué en el anfitrión

Componente	Dónde	Por qué
PostgreSQL, ETL, Grafana, simulador	Contenedor	Son los componentes de servidor; se reproducen con un comando
Power BI Desktop	Anfitrión (Windows/VMware)	Es una aplicación de escritorio solo para Windows
DBeaver	Anfitrión	Es un cliente de escritorio

PostgreSQL publica el puerto **55432** del anfitrión (no el 5432, para no chocar con una instalación local), y así Power BI y DBeaver se conectan desde fuera del contenedor.

---

4. Flujo de una cifra, de principio a fin

Para fijar la arquitectura, el recorrido de un dato concreto:

1. **07:00.** La operaria de Vinilos_2 anota en el formato de papel: 42 pacas, referencia Parchesitos 125 cc, paro de 12 min por código 05 con subcódigo 5.2.
2. **Al final del turno**, producción remite el formato a mantenimiento.
3. **Mantenimiento digita** la fila en la hoja `Registro` y pulsa «Ingreso total»; la macro la escribe en `Base De Datos`, fila 4.317.
4. **`docker compose up`.** El ETL lee la fila 4.317, la carga en `stg.base_datos` como texto y registra el SHA-256 del archivo.
5. **Fase de dimensiones.** «Parchesitos 125 cc» resuelve a `referencia_key = 31`; el estándar vigente de (Vinilos_2, 31) da una tasa ideal de 48 unidades/min; el subcódigo `5.2` resuelve al sistema `SYS-DOSIF`, «Sistema de dosificación de pintura».
6. **Fase de hechos.** Se crea una fila en `hecho_produccion_turno` con `horas_programadas = 8`, `horas_paro_total = 0,2`, `unidades_producidas = 42 × 24 = 1.008` y una `Disponibilidad` de 0,975. Y una fila en `hecho_paro` con `minutos_paro = 12`, apuntando al sistema dosificador.
7. **Fase de calidad.** La fila pasa las 21 reglas sin banderas.
8. **Fase de conciliación.** Sus 8 horas y sus 42 pacas entran en los totales que se contrastan contra las tablas dinámicas del Excel.
9. **Grafana** la muestra en el Pareto del turno; **Power BI** la suma al OEE del mes y la compara contra el mismo mes del año anterior.

10. **El coordinador de mantenimiento** ve que el sistema dosificador acumula el 44,6 % del tiempo perdido con causa raíz identificable y lo lleva al comité con una cifra, no con una impresión.

8 Power BI y Grafana

La pregunta que hay que responder no es «cuál es mejor», sino **por qué no se intercambian**. Las dos herramientas leen la misma base de datos, así que la diferencia no está en el dato: está en el tipo de pregunta.

---

1. La distinción de fondo

> **Grafana responde «¿qué está pasando?». Power BI responde «¿qué está cambiando?».**

Son dos problemas técnicos distintos:

- **«Qué está pasando»** necesita el **último** dato y lo necesita ya. El horizonte es de minutos y la consulta toca pocas filas recientes. La pregunta no admite espera.
- **«Qué está cambiando»** necesita **todo el histórico** y compararlo contra un periodo anterior. El horizonte es de meses y la consulta recorre años de datos. La pregunta no admite imprecisión.

Casi todo lo demás se deduce de ahí.

---

2. Comparación

	Grafana	Power BI
Pregunta que resuelve	¿Qué línea está en rojo **ahora** y qué la está frenando?	¿Cómo evolucionó el OEE y por qué, comparado con el año pasado?
Usuario	U1 operaria, U2 supervisor de turno, U3 coordinador de mantenimiento (uso diario)	U3 (informe mensual), U4 jefe de producción, U5 gerencia
Horizonte	Las últimas 24 horas	2022–2025, con comparativos interanuales
Frecuencia de actualización	**10 segundos** (consulta directa a PostgreSQL)	**Importación**, refresco diario o a demanda
Grano que consume	`hecho_produccion_hora` (hora × máquina)	`hecho_produccion_turno` y `hecho_paro` (turno y evento)
Dónde se mira	Pantalla fija en el piso de planta	Portátil, en una reunión
Interacción	Mirar. Como mucho, cambiar una variable	Explorar: segmentar, hacer drill-down, cruzar
Modelo de datos	Ninguno: SQL directo sobre vistas	Modelo semántico con 10 relaciones, 2 jerarquías y 36 medidas DAX
Alertas	**Sí**, nativas y con estado (Normal → Pending → Firing) y notificación saliente	No en el escritorio; requiere el servicio en la nube
Cálculos complejos	Lo que quepa en SQL	DAX: inteligencia de tiempo, contexto de filtro, Pareto acumulado
Versionado	JSON del tablero + YAML de provisioning	PBIP/TMDL (texto)
Costo	Libre, en el contenedor	Licencia; Desktop gratis, publicar requiere Pro

---

3. Por qué Grafana no puede hacer el trabajo de Power BI

3.1. No tiene modelo semántico

Grafana ejecuta SQL y dibuja el resultado. **No hay capa semántica**: cada panel lleva su propia consulta. Consecuencias concretas:

- La definición del OEE queda **repetida en cada panel**. Si mañana se decide excluir los paros planeados del denominador, hay que editar los paneles uno por uno. En Power BI se cambia **una** medida DAX y se propaga a todo el informe.

- **No hay contexto de filtro.** El `% acumulado de tiempo perdido` del Pareto en DAX se recalcula solo cuando el usuario filtra por máquina o por mes, porque la medida se evalúa en el contexto vigente. En Grafana hay que escribir la función de ventana en el SQL del panel, y solo funciona para las variables que ese panel contemple.

3.2. La inteligencia de tiempo es manual

`SAMEPERIODLASTYEAR` y `TOTALYTD` resuelven en una línea el problema de comparar contra el año anterior respetando años bisiestos, meses incompletos y el filtro vigente. En Grafana hay que escribirlo en SQL —por eso `dim_fecha` trae `fecha_key_anio_ant` precalculada— y no responde a los filtros del usuario.

3.3. No se explora, se mira

Un tablero de Grafana está pensado para leerse de un vistazo. No tiene drill-down por jerarquías, ni tablas cruzadas, ni la capacidad de que un gerente pregunte «¿y si miro solo el turno de noche de Vinilos_2 en el segundo semestre?» sin que alguien le reprograme un panel.

3.4. Importar frente a consultar

Grafana consulta **en vivo**, que es su virtud y su límite. Un panel que recorriera 5.138 turnos × 16.482 paros con funciones de ventana sobre tres años tardaría segundos en cada refresco, y con refresco de 10 s castigaría a la base sin motivo: **el histórico de 2023 no cambia**. Power BI importa el modelo a memoria y lo recorre al instante.

---

4. Por qué Power BI no puede hacer el trabajo de Grafana

4.1. No tiene alertas en el escritorio

Es la razón decisiva. Un supervisor no mira una pantalla todo el turno: hay que **avisarle**. El proyecto lo demuestra de punta a punta: la alerta de OEE crítico pasa por `Normal → Pending → Firing`, y la notificación llega a su destinatario con la línea afectada, el valor y el umbral.

Power BI Desktop no alerta. Las alertas de Power BI requieren publicar en el servicio en la nube, con licencia Pro, y se evalúan **cada 15 minutos como máximo** sobre un modelo que puede llevar horas sin refrescar. Para un paro de 12 minutos eso no sirve.

4.2. La latencia es estructural, no un ajuste

Power BI **importa**. Entre el momento productivo y la cifra en pantalla hay un refresco de por medio: en Desktop, cuando alguien lo pulsa; publicado, hasta 8 refrescos programados al día con licencia Pro. El modo DirectQuery reduce la latencia pero inutiliza buena parte de DAX y vuelve lenta la exploración.

Grafana consulta con `$__timeFilter(instante)` cada 10 segundos. La diferencia entre 10 segundos y 3 horas no es de grado: decide si el dato sirve para actuar durante el turno.

4.3. No corre en el piso de planta

El tablero operativo tiene que vivir en una pantalla fija, encendida todo el turno, sin que nadie inicie sesión. Grafana es una página web: se abre y se deja. Power BI Desktop es una aplicación de Windows que exige una licencia por usuario y una sesión abierta.

4.4. No es contenerizable

Power BI Desktop solo existe para Windows y no se contenedoriza, de ahí que en esta arquitectura corra en el anfitrión. Grafana es parte de la pila y se levanta con el mismo comando, con su tablero y su alerta ya cargados por provisioning.

---

5. Cómo se reparten el trabajo sin duplicarlo

El riesgo de tener dos herramientas es que den números distintos. Se evita con tres reglas:

1. **Una sola fuente de verdad.** Las dos leen `dw` con el rol `bi_lectura`. Ninguna lee el Excel y ninguna guarda su propia copia transformada.
2. **Las definiciones viven en la base de datos.** `naturaleza_paro`, `tiene_estandar`, `rendimiento_implausible` y los componentes del OEE se calculan en el ETL y se almacenan. Grafana y Power BI **consumen** la definición, no la reimplementan. Si mañana cambia el criterio de qué paro es planeado, se cambia en un sitio.

3. **Cada tablero tiene su grano.** Grafana lee `hecho_produccion_hora` (telemetría); Power BI lee `hecho_produccion_turno` y `hecho_paro` (histórico auditado). No compiten por el mismo dato.

Reparto por indicador

Indicador	Grafana	Power BI
Semáforo de estado actual por línea	✓	
Líneas sin reportar	✓	
OEE y componentes de la última hora	✓	
Minutos de paro por hora y causa	✓	
Pareto del turno en curso	✓	
Alerta de OEE crítico	✓	
OEE mensual y anual por línea		✓
Comparativo interanual		✓
OEE acumulado del año		✓
Drill-down de la jerarquía de paros		✓
Pareto del histórico		✓
MTBF y MTTR		✓
Rendimiento por referencia		✓
Utilización del calendario		✓
Índice de completitud del registro		✓

El **Pareto aparece en las dos**, y no es una duplicación: en Grafana es el Pareto del rango seleccionado, para decidir a qué atender ahora; en Power BI es el del histórico, con el porcentaje acumulado recalculándose según los filtros, para decidir el plan de mantenimiento del trimestre. Misma forma de gráfico, decisiones distintas.

---

6. Qué pasaría si se eligiera solo una

Solo Grafana. Se mantiene la operación diaria, pero el comité mensual vuelve al Excel, porque Grafana no compara periodos con soltura ni permite explorar. Y se perdería el drill-down de la jerarquía de paros, que es donde está el hallazgo del sistema dosificador.

Solo Power BI. Se tiene un informe gerencial excelente y **la planta sigue sin saber que una línea está parada**. El circuito de retroalimentación con la operaria —hoy inexistente: entrega el formato en papel y nunca ve el resultado— seguiría sin cerrarse. Y sin alertas, el valor del dato near real time se pierde por completo.

Dicho de otro modo: Power BI mejora **las decisiones del mes**; Grafana mejora **las decisiones del turno**. La planta pierde dinero en los dos horizontes.

9 Evolución a PLC/SCADA

1. El punto de partida

Hoy el dato recorre este camino, descrito en el apartado 4.1 del P-MTO-22:

```
operaria escribe a mano  →  producción recoge el formato  →  mantenimiento
lo remite  →  mantenimiento lo digita en el Excel  →  informe mensual
```

Son **cuatro traspasos manuales** y una latencia de días o semanas. Eso explica casi todos los problemas documentados en el diagnóstico: los 42 duplicados, las 45 variantes de escritura de un mismo subcódigo, los turnos de 32 horas, los paros de 15,63 h en turnos de 8, y que en 2022 no haya ni un registro con operario.

La buena noticia: el modelo dimensional ya está preparado. La tabla `dw.hecho_produccion_hora` existe, tiene el grano horario que entregaría un historiador, incluye una columna `unidades_rechazadas` que el Excel no tiene, y el tablero de Grafana ya consume de ella. Lo que hoy la alimenta es el simulador; mañana sería el PLC. **El modelo no cambia.**

---

2. Qué se instrumenta y qué resuelve cada cosa

Señal	Sensor	Qué problema resuelve
Contador de unidades en la salida	Fotocélula o encoder ya presente en la mayoría de líneas de envasado	Elimina la digitación de pacas. Acaba con los 22 turnos de rendimiento implausible
Estado de marcha / parada	Señal del variador o del contactor principal	Elimina la digitación de minutos de paro. Acaba con los paros mayores que el turno
Unidades rechazadas	Fotocélula en el expulsor, o báscula de control	**Convierte el componente Calidad del OEE en una medición real.** Hoy es un proxy basado en 9,05 h de reproceso en todo el histórico
Causa del paro	**Pantalla HMI en la línea** con los 18 códigos y sus subcódigos	Es el punto crítico; ver abajo
Referencia en proceso	Orden de producción desde el ERP, o lectura de código de barras	Elimina las 52 variantes de escritura y las 2.390 filas sin referencia
Presión de aire y energía	Transductores en la red de aire comprimido	Automatiza el código 03 y permite correlacionar caídas de presión con paros de otros códigos

2.1. La causa del paro sigue necesitando a una persona

Es el punto que conviene no prometer de más. Un PLC sabe **que** la máquina paró y **cuánto** tiempo, pero no **por qué**. Distinguir «ajuste operativo» de «falla del sistema dosificador» es un juicio humano.

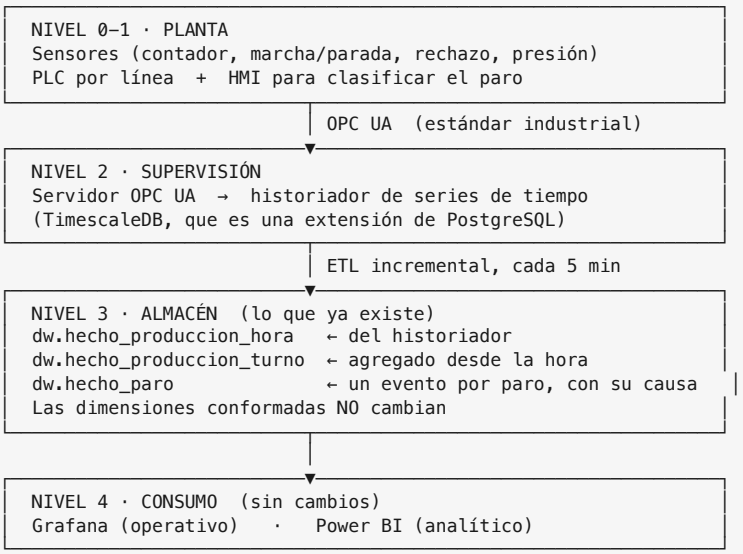
La propuesta: **el PLC detecta el paro y la HMI pregunta la causa.** En cuanto la línea se detiene más de un umbral (30 s, por ejemplo), la pantalla muestra los 18 códigos y, al elegir 01, 03 o 05, despliega el árbol de subcódigos. El operario toca dos botones y la duración ya está medida por el autómata.

Ventajas sobre el formato en papel:

- **La duración deja de depender de la memoria.** El operario ya no estima «unos 15 minutos».
- **El subcódigo se elige de una lista**, no se escribe. Desaparecen las 45 variantes de escritura y las dos taxonomías conviviendo.
- **El dato no se puede duplicar**, porque cada paro tiene su marca de tiempo.
- **Lo registra quien ve el problema**, no quien digita días después.
- **Es obligatorio y bloqueante**: la línea no se reporta como productiva hasta que se clasifique el paro. Eso resuelve las 5.020 apariciones de «Sin especificar» mejor que cualquier regla de limpieza.

---

3. Arquitectura propuesta



3.1. Por qué OPC UA

Es el estándar de interoperabilidad industrial: lo hablan Siemens, Allen Bradley, Schneider y Omron. Usar el protocolo propietario de un fabricante ataría el proyecto a esa marca, y en una planta con líneas de distinta procedencia eso es un problema a los dos años.

3.2. Por qué TimescaleDB y no otra base

Porque es una extensión de PostgreSQL, no otra base de datos. Convierte `hecho_produccion_hora` en una *hypertable* particionada por tiempo, con compresión y agregados continuos, **sin cambiar una sola consulta**: el mismo SQL, los mismos roles, el mismo datasource de Grafana, el mismo modelo de Power BI. Introducir InfluxDB o Prometheus obligaría a mantener dos motores, dos lenguajes de consulta y dos esquemas de permisos.

3.3. Qué habría que tocar en el proyecto actual

Componente	Cambio
`dw.hecho_produccion_hora`	Ninguno en la estructura. Pasa a *hypertable*
`dw.hecho_produccion_turno`	Deja de cargarse del Excel y pasa a ser un **agregado continuo** de la tabla horaria
`dw.hecho_paro`	Igual, pero con marca de tiempo de inicio y fin reales en vez de minutos totales por turno
Dimensiones	**Sin cambios.** Son conformadas y ya están
ETL	Cambia la extracción (OPC UA en vez de `openpyxl`) y pasa a incremental. **Las reglas de calidad y la conciliación se conservan**: seguirán haciendo falta, porque un sensor sucio también miente
Simulador	Se retira. Su función era precisamente ocupar el lugar del PLC
Grafana	**Sin cambios.** Ya lee la tabla horaria
Power BI	**Sin cambios** en el modelo. Solo gana granularidad
`dim_fecha`	Habría que añadir una dimensión de **hora del día** si se quiere analizar patrones intradía

El diseño del modelo dimensional es, en este sentido, la inversión que sobrevive al cambio de fuente.

---

4. Lo que se gana, por orden de valor

4.1. El componente Calidad del OEE deja de ser un proxy

Es la ganancia mayor. Hoy la Calidad se estima con el tiempo de reproceso y da un valor cercano al 100 % que con casi total seguridad es optimista. Con una fotocélula en el expulsor el OEE pasa a ser **el OEE de verdad**, y la planta descubre cuánto le cuesta producir mal, que es un número que hoy **no existe**.

4.2. El OEE se vuelve accionable dentro del turno

Un paro de 20 minutos hoy se conoce la semana siguiente. Con dato en línea, la alerta de OEE crítico —ya construida y probada— llega al supervisor mientras el turno está corriendo. Un turno de 8 horas tiene 480 minutos: avisar en el minuto 30 en lugar del día siguiente es la diferencia entre corregir y lamentar.

4.3. Micro-paros

El formato actual no puede registrar un paro de 40 segundos: nadie lo anota. En una línea de envasado los micro-paros son una de las pérdidas más grandes y más invisibles. Un PLC los cuenta todos. Es probable que al instrumentar, el OEE medido **baje**, y eso sería una buena señal: significaría que se dejó de contar como productivo un tiempo que no lo era.

4.4. Se liberan horas de mantenimiento

Hoy alguien del área digita 8.208 filas en el Excel. Ese trabajo desaparece, y es tiempo de un técnico que puede dedicarse a mantener máquinas.

4.5. El dato queda auditable por construcción

Ni duplicados, ni variantes de escritura, ni turnos de 32 horas. Los problemas que hoy exigen 21 reglas de limpieza dejan de existir en el origen, que es donde hay que resolverlos.

---

5. Plan por fases

Fase	Alcance	Qué habilita
0 · Ya hecho	Modelo dimensional, ETL, tableros, alerta	Medir OEE con el dato que existe y cuantificar las brechas
1 · Piloto en una línea	Contador y marcha/parada en Vinilos_1, la de peor OEE sostenido (49,7 % en 2023 y 48,7 % en 2024). HMI con los 18 códigos	Comparar el dato automático con el manual **sobre la misma línea y el mismo turno**. Es la validación que justifica el resto de la inversión
2 · Extensión	Las cuatro líneas, más la referencia desde el ERP	OEE horario real en toda la planta
3 · Calidad	Detección de rechazo en el expulsor	El componente Calidad deja de ser un proxy. **OEE completo y auditable**
4 · Servicios	Presión de aire y energía	Automatiza el código 03 y permite correlacionar la caída de presión con los paros de otros códigos
5 · Analítica avanzada	Modelos de predicción de falla sobre el histórico horario	Mantenimiento predictivo. **Requiere las fases anteriores**: sin años de dato horario fiable no hay nada que entrenar

Por qué empezar por Vinilos_1

Porque es donde el argumento se defiende solo. Su disponibilidad cayó de **89,7 % (2022) a 65,7 % (2024)** y su OEE lleva dos años por debajo del umbral crítico: **49,7 % en 2023 y 48,7 % en 2024**. Al mismo tiempo, Vinilos_3 y Vinilos_4 sostienen 72–74 % con los mismos equipos y el mismo producto, de modo que la brecha no se explica por el equipo.

En el primer trimestre de 2025 Vinilos_1 repunta a 66,8 %, pero sobre **95 turnos** frente a los 451 de 2024: es un año parcial y una base demasiado pequeña para concluir que el problema se resolvió. Precisamente por eso conviene instrumentarla: hoy no hay forma de saber si mejoró la línea o solo cambió lo que se le cargó.

Si el piloto demuestra en una línea que el dato automático revela pérdidas que el formato en papel no veía, la extensión a las otras tres deja de ser una discusión.

---

6. Lo que no resuelve la instrumentación

Conviene ser explícito, porque prometer de más es la forma más rápida de perder credibilidad en el comité:

- **No mejora el OEE por sí misma.** Medir mejor no produce más. Lo que hace es que las decisiones se tomen sobre hechos.
- **No elimina el juicio humano** en la causa del paro, solo lo ordena y lo pone en el momento y el lugar correctos.
- **No sirve si nadie mira el tablero.** El circuito se cierra cuando la operaria recibe retroalimentación y el supervisor actúa sobre la alerta. Eso es un cambio de hábito, no de tecnología.
- **No arregla el histórico.** Los datos de 2022 a 2025 seguirán teniendo las limitaciones documentadas. El OEE comparable empieza el día que se instrumenta, y conviene decirlo antes de que alguien compare un OEE de 2024 con uno de 2027 y crea que la planta empeoró.

10 Datos personales y seguridad

1. Qué datos personales trae la fuente

El Excel contiene datos personales de dos grupos de personas, y conviene decir exactamente cuáles:

Dato en la fuente	Columna	Volumen	Naturaleza
Nombre de la operaria o el operario del turno	«Operario»	34 valores distintos en 5.588 filas	**Dato personal.** En su mayoría nombre de pila, algunos con apellido
Nombre del técnico que atendió el paro	«Personal involucrado» (código 05)	38 valores distintos en 1.767 filas	**Dato personal.** Nombre y apellidos completos
Lista nominal de personal	hoja `Tiempos`	45 nombres	**Dato personal**

Lo importante no es solo el nombre. Al cruzarlo con el resto de las columnas, la fuente permite reconstruir **el desempeño individual, el historial de turnos y la asistencia** de una persona identificada. Esa combinación —no el nombre aislado— es el riesgo real: convierte una base de producción en una base de evaluación de personal, sin que nadie lo haya decidido.

1.1. Marco legal aplicable

La planta está en Colombia, de modo que rige la **Ley 1581 de 2012** de protección de datos personales y su **Decreto reglamentario 1377 de 2013**. Los principios que condicionan el diseño:

- **Finalidad.** Los datos solo pueden tratarse para el fin informado al titular. Quien entregó su nombre para un registro de producción no autorizó que se use para evaluarlo.
- **Necesidad.** Solo deben tratarse los datos que la finalidad requiera.
- **Acceso restringido.** Los datos no son de acceso libre, ni siquiera dentro de la empresa.
- **Seguridad.** El responsable debe adoptar medidas técnicas para impedir acceso no autorizado.

---

2. La decisión de diseño: medir la línea, no a la persona

La finalidad declarada del proyecto es medir el desempeño de las máquinas, no de las personas. El OEE es un indicador de equipo: se descompone en disponibilidad, rendimiento y calidad, y ninguno de los tres mejora porque se señale a un operario.

De esa finalidad se derivan tres consecuencias prácticas:

1. **Ninguna dimensión de persona llega al tablero con nombre.** No porque sea difícil, sino porque no hace falta para la finalidad declarada.
2. **El turno sí se analiza; la persona no.** El indicador por turno (consulta C07) responde una pregunta legítima de organización del trabajo: si el turno de noche rinde distinto, eso es un problema de supervisión, iluminación o relevos, no de quién estaba. La consulta lleva una **nota de privacidad escrita en el propio SQL** advirtiendo que no debe usarse para identificar personas, porque un turno pequeño puede tener un solo operario asignado.
3. **El dato se conserva pseudonimizado, no se destruye.** Si en el futuro la empresa quisiera un análisis nominal, tendría que informar a los titulares y obtener autorización. El diseño deja esa puerta cerrada, no tapiada, y el camino para abrirla es documentado y auditable.

---

3. Pseudonimización: cómo se implementa

3.1. Lo que llega al almacén

En el momento de construir las dimensiones, cada nombre se sustituye por un **pseudónimo estable**:

En la fuente	En `dw.dim_operario`
El nombre real	`codigo_operario = 'OPR-003'`, `alias_operario = 'Operario 003'`

El nombre real se guarda **en una sola tabla de un esquema aparte**, `pii.operario_identidad`, junto a la huella que lo vincula con el pseudónimo:

```
HMAC-SHA256(nombre_normalizado, semilla_secreta)
```

Decisiones concretas y por qué:

- **HMAC con semilla, no un hash simple.** Un `SHA-256` del nombre es trivialmente reversible: hay pocos nombres de pila en uso y cualquiera puede precalcular un diccionario. La semilla secreta —que vive en la variable de entorno `ETL_SALT_PSEUDONIMO` y **no está en el repositorio**— convierte ese ataque en inviable.
- **La huella vive solo en `pii`.** Es la llave de vinculación entre el pseudónimo y la persona, luego es un dato personal en sí misma y debe quedar tras la política de seguridad a nivel de fila. **En `dw` no existe**: ahí solo queda `OPR-003`, que por sí solo no reidentifica a nadie.
- **El pseudónimo es estable entre cargas.** La misma persona recibe siempre el mismo código, de modo que el histórico sigue siendo coherente sin necesidad de conservar su nombre en el modelo analítico.
- **Los marcadores de ausencia se consolidan.** La fuente usa «No» y «No aplica» como marcadores; van al miembro técnico `OPR-000` «Sin informar», y no se tratan como si fueran personas.

3.2. Separación por esquema

Esquema	Qué contiene	Quién lo lee
`dw`	Pseudónimos y alias, sin nombres ni huellas	Grafana y Power BI (`bi_lectura`)
`pii`	Los nombres reales y las huellas, con RLS activo	Solo `pii_reidentificacion`
`stg`	La zona de aterrizaje, que **sí** tiene el nombre en crudo	Solo `bi_admin`

`stg` merece la mención explícita: es la copia literal de la fuente y por tanto contiene los nombres sin pseudonimizar. Por eso se le **revoca el acceso de forma expresa** al rol de los tableros, igual que a `pii`.

---

4. Reidentificación controlada

Negar todo acceso sería cómodo pero irreal: el coordinador de mantenimiento puede tener una **finalidad legítima** para saber quién atendió una avería concreta —por ejemplo, preguntarle qué vio—. El diseño no lo prohíbe: lo canaliza.

- Existe un **rol de finalidad única**, `pii_reidentificacion`, creado `NOLOGIN`. No es una cuenta: es una autorización que se concede de forma **nominal y temporal** a una cuenta concreta, y cuya asignación debe quedar registrada por el responsable del tratamiento.
- El **único camino previsto** son las vistas `pii.v_reidentificar_operario` y `pii.v_reidentificar_personal`, que exponen el mínimo necesario: pseudónimo → nombre, nada más. No dan acceso al historial de turnos ni al desempeño.
- Las vistas son `SECURITY INVOKER` (el comportamiento por defecto), de modo que la política de seguridad a nivel de fila se evalúa con los privilegios de **quien consulta**, no del propietario. Sin esto, la vista sería una puerta trasera para cualquiera con `SELECT` sobre ella.
- **Ningún tablero usa ese rol.** Grafana y Power BI se conectan con `bi_lectura`, que no lo tiene.

---

5. Seguridad de acceso a los tableros

5.1. Mínimo privilegio en la base de datos

Rol	Para qué	Privilegios
`bi_admin`	DDL y ejecución del ETL	Superusuario del contenedor. **No lo usa ningún tablero**
`bi_analista`	Rol de grupo, `NOLOGIN`	`SELECT` sobre `dw` y `aud`. Concentra los permisos en un sitio
`bi_lectura`	**El que usan Grafana y Power BI**	Hereda de `bi_analista`. Nada más
`pii_reidentificacion`	Finalidad única, `NOLOGIN`	Las dos vistas de reidentificación

Medidas concretas:

- **`REVOKE ALL ON SCHEMA public FROM PUBLIC`.** PostgreSQL concede por defecto permiso de creación en `public` a cualquier rol; sin esto, el rol del tablero podría crear objetos en la base.
- **`REVOKE ALL ON DATABASE ... FROM PUBLIC`**, y `CONNECT` concedido solo al rol de grupo.
- **Revocación expresa** de `pii` y `stg`, en lugar de simplemente no concederlos: deja constancia de la decisión en el código, que es lo que hace auditable un modelo de permisos.
- **`CONNECTION LIMIT 20`** sobre `bi_lectura`: un tablero mal configurado con refresco de 10 segundos no puede agotar el conjunto de conexiones.
- **`ALTER DEFAULT PRIVILEGES`**: si mañana el ETL crea una vista nueva en `dw`, el permiso ya está dado y nadie tiene que acordarse de concederlo; y si la crea en `pii`, sigue revocado por defecto.

5.2. Seguridad a nivel de fila como segunda capa

Las dos tablas de `pii` tienen `ENABLE` y **`FORCE ROW LEVEL SECURITY`**, con una política que solo devuelve filas a quien pertenezca a `pii_reidentificacion`.

`FORCE` es la parte que importa: sin él, el **propietario de la tabla** se salta su propia política. Con él, ni el propietario ve las filas si no tiene la finalidad.

Es defensa en profundidad: si alguien concediera `USAGE` sobre `pii` por error, la política seguiría negando las filas. **Está demostrado abajo**, no solo afirmado.

5.3. Credenciales fuera del repositorio

Es un requisito explícito del enunciado y se cumple así:

- **Ningún archivo versionado contiene una contraseña ni una cadena de conexión con contraseña.** `docker-compose.yml` referencia `${POSTGRES_PASSWORD}` y similares.
- Los valores viven en **`.env`, excluido por `.gitignore`**. Se versiona **`.env.example`** con los nombres de las variables y comentarios sobre qué poner en cada una.
- El **datasource de Grafana** recibe la contraseña por interpolación de la variable de entorno en el archivo de provisioning. El YAML versionado no la contiene.
- El **proyecto de Power BI** no guarda credenciales: el archivo `expressions.tmdl` solo tiene el servidor y el nombre de la base. Power BI pide la contraseña al abrir y la guarda en el administrador de credenciales de Windows.
- La **semilla de pseudonimización** (`ETL_SALT_PSEUDONIMO`) es también una variable de entorno. Es el secreto más sensible del proyecto: quien la tenga puede reconstruir el vínculo entre pseudónimo y nombre si además consigue la lista de nombres.

5.4. Acceso a la interfaz de los tableros

- **Grafana** exige autenticación; el usuario y la contraseña del administrador llegan por variables de entorno. En producción habría que integrarlo con el directorio de la empresa y usar las carpetas de Grafana para que cada perfil vea solo sus tableros.
- **`allowUiUpdates: false`** en el provisioning: nadie puede modificar el tablero desde la interfaz. Para cambiarlo hay que editar el JSON y versionarlo. Protege la integridad de lo que se publica y evita que el repositorio quede desactualizado.
- **El puerto de PostgreSQL se publica en el anfitrión** (55432) para que Power BI y DBeaver puedan conectarse desde la máquina virtual. Es una exposición deliberada y acotada: el rol que se usa desde fuera es `bi_lectura`, que solo puede leer `dw` y `aud`. En producción esa conexión debería ir por la red interna o por un túnel, no por la red local.

5.5. Advertencia honesta sobre el entorno

Esto es un montaje de desarrollo y conviene no presentarlo como otra cosa:

- Las contraseñas de `.env` son **de desarrollo** y están señaladas como tales. En producción deberían venir de un gestor de secretos.
- El tráfico entre Power BI y PostgreSQL **no va cifrado con TLS**. En producción habría que exigir `sslmode=require`.
- No hay registro de auditoría de **quién consultó qué**. Si la empresa concediera el rol de reidentificación, convendría activar `pgaudit` para dejar rastro de cada acceso a `pii`.

---

6. Evidencia: lo que está comprobado, no solo afirmado

Ejecutado contra la base recién reconstruida desde cero.

A · La huella de identidad no existe en el almacén

```
columnas hash_identidad en dw  : 0
columnas hash_identidad en pii : 2
```

B · Lo que el rol de los tableros sí ve

```
SET ROLE bi_lectura;
SELECT codigo_operario, alias_operario, rol, turnos_registrados FROM dw.dim_operario;
```

```
 codigo_operario | alias_operario |         rol          | turnos_registrados
-----------------+----------------+----------------------+--------------------
 OPR-000         | Sin informar   | Sin informar         |               2620
 OPR-003         | Operario 003   | Operario de envasado |                254
```

Sirve para medir —254 turnos registrados— y no identifica a nadie.

C · Lo que el rol de los tableros no puede hacer

```
SELECT * FROM pii.operario_identidad;        -- ERROR: permission denied for schema pii
SELECT * FROM stg.base_datos;                -- ERROR: permission denied for schema stg
SELECT * FROM pii.v_reidentificar_operario;  -- ERROR: permission denied for schema pii
DELETE FROM dw.hecho_paro WHERE false;       -- ERROR: permission denied for table hecho_paro
```

Aunque alguien obtuviera la cadena de conexión del tablero, **no puede leer un solo nombre propio ni alterar un solo hecho**.

D · La seguridad a nivel de fila bloquea por sí sola

Se creó un rol con `USAGE` sobre `pii` y `SELECT` sobre la tabla —es decir, simulando una concesión por error— pero **sin** pertenecer a `pii_reidentificacion`:

```
GRANT USAGE ON SCHEMA pii TO demo_sin_finalidad;
GRANT SELECT ON pii.operario_identidad TO demo_sin_finalidad;
SET ROLE demo_sin_finalidad;
SELECT count(*) FROM pii.operario_identidad;
```

```
 filas_visibles_sin_finalidad
------------------------------
                            0
```

Tiene el permiso y **no ve ninguna de las 43 filas**. Esto es lo que demuestra que la protección no depende únicamente de haber configurado bien los privilegios de esquema. (El rol de prueba se eliminó tras la comprobación.)

E · El rol con finalidad legítima sí puede reidentificar

```
SET ROLE pii_reidentificacion;
SELECT count(*) FROM pii.operario_identidad;          -->  43
SELECT codigo_operario, alias_operario, nombre_fuente
  FROM pii.v_reidentificar_operario;
```

```
 codigo_operario | alias_operario | nombre (enmascarado en esta evidencia)
-----------------+----------------+----------------------------------------
 OPR-001         | Operario 001   | A******
 OPR-002         | Operario 002   | A******
```

El mecanismo funciona para quien tiene la finalidad, y solo para quien la tiene.

> Los nombres aparecen enmascarados **en este documento**, no en la base: sería incoherente documentar un modelo de protección de datos personales imprimiendo los nombres reales en el entregable.

F · El repositorio no contiene credenciales

`.env` está excluido:

```
$ grep -x "\.env" .gitignore
.env
```

Y la búsqueda de valores literales de contraseña en todo lo versionado no devuelve ninguno:

```
$ grep -rEn "(PASSWORD|password)[[:space:]]*[:=][[:space:]]*[\"']?[A-Za-z0-9_]" \
      docker-compose.yml grafana/provisioning/ powerbi/ sql/ etl/ simulador/ \
  | grep -v '\${'
sql/init/60_permisos.sql:38:ALTER ROLE :"ro_user" WITH PASSWORD :'ro_pass';
```

La única coincidencia es `:'ro_pass'`, una **variable de psql** que se resuelve en tiempo de ejecución desde `BI_READONLY_PASSWORD`, no un valor literal. Todo lo demás son referencias `${VARIABLE}`.

G · El repositorio tampoco contiene los nombres reales

Sería incoherente pseudonimizar los nombres en la base de datos y a la vez publicar en GitHub el archivo que los contiene. El `.xlsm` de origen trae los **nombres reales de 45 personas**, así que está excluido del control de versiones:

```
$ git check-ignore -v "datos/fuente/Seguimiento Temperas y Vinilos Actividad.xlsm"
.gitignore:92:datos/**/*.xlsm   datos/fuente/Seguimiento Temperas y Vinilos Actividad.xlsm
```

La reproducibilidad no se pierde: `datos/fuente/README.md` **sí** se versiona y registra el **SHA-256** del libro (`c7d7eabb…92d5c55`), de modo que quien reponga el archivo puede verificar que es exactamente el mismo con el que se calcularon las cifras del informe. El ETL registra además ese hash en `aud.ejecucion_etl` en cada ejecución.

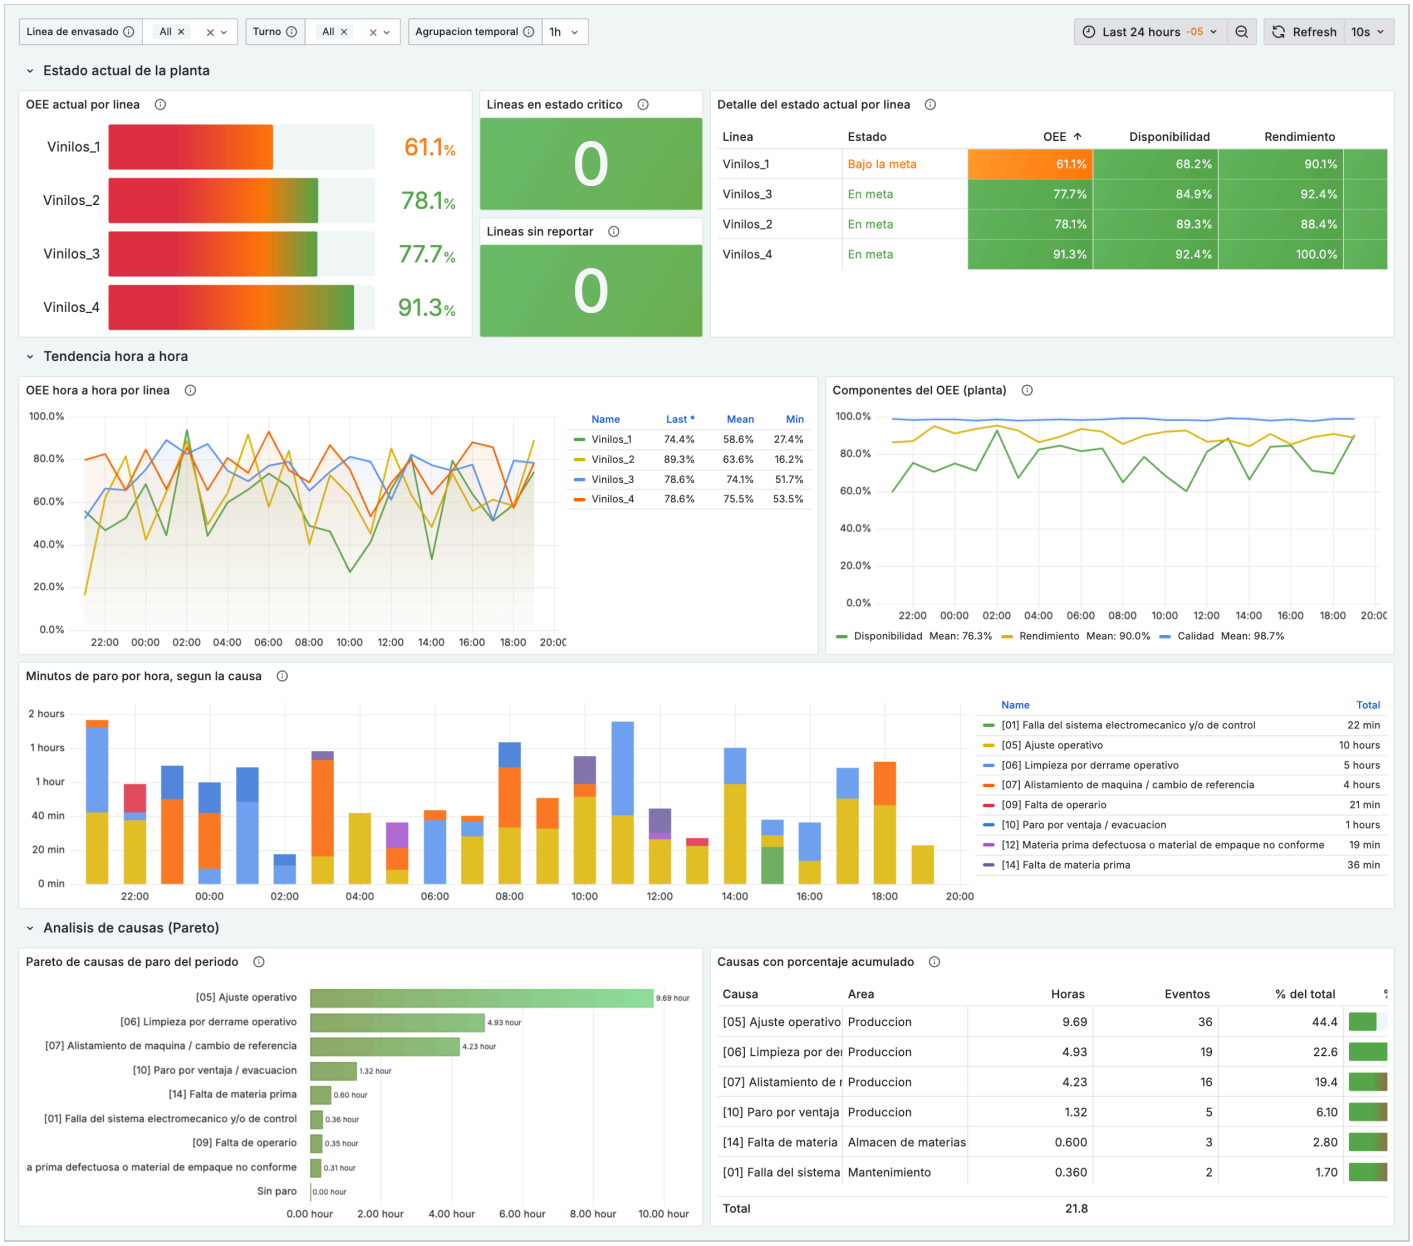
---

7. Qué recomendar a la empresa

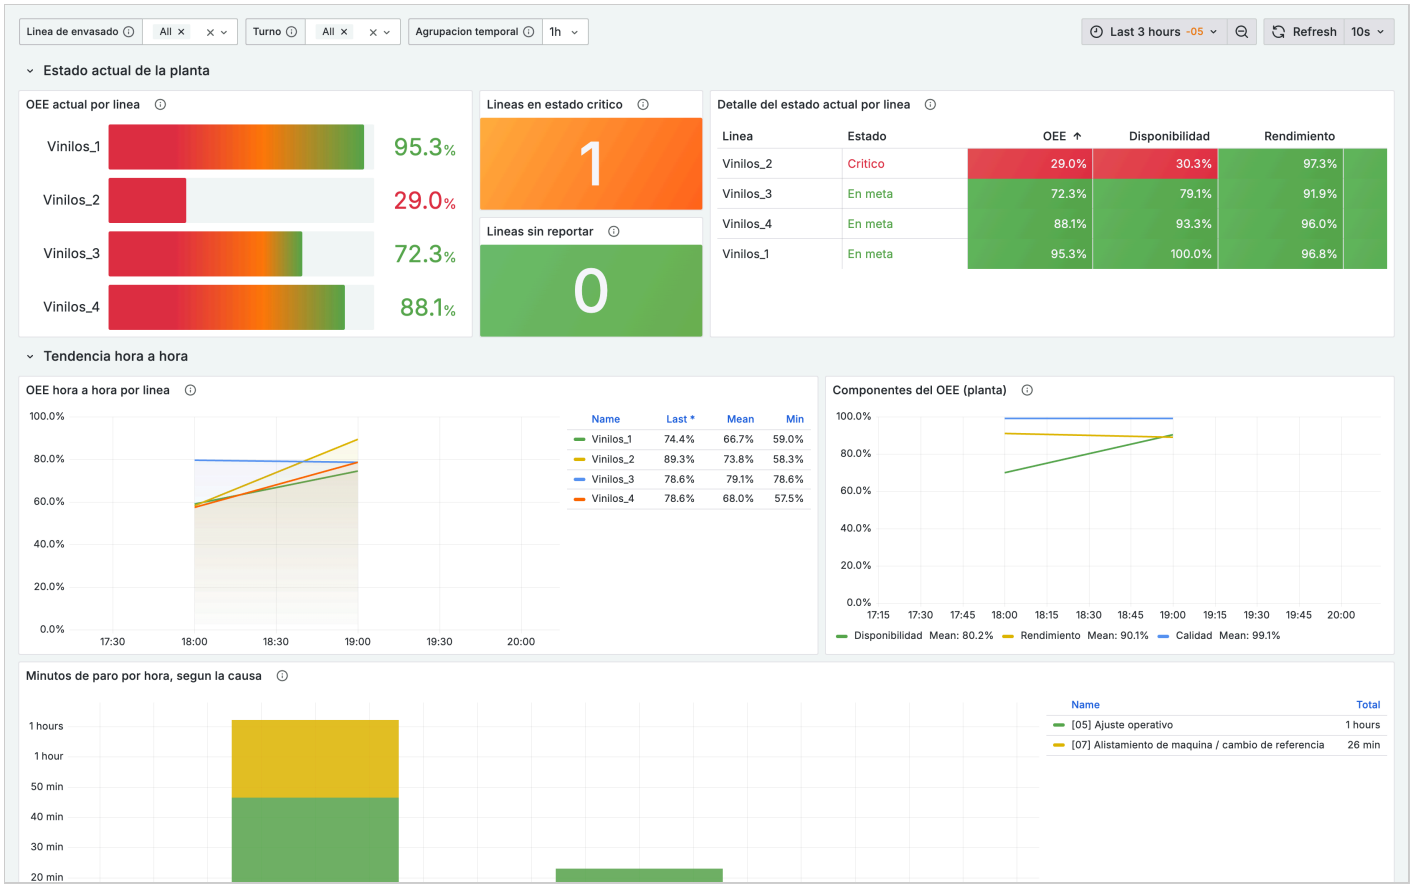
Más allá de lo implementado, tres cosas que el proyecto no puede resolver por su cuenta:

1. **Informar a los titulares.** Las operarias y el personal de mantenimiento deberían saber que su nombre se registra, para qué y por cuánto tiempo. Es una obligación de la Ley 1581 y hoy no consta que se cumpla.
2. **Decidir si el nombre hace falta en el formato.** Si la finalidad es medir la máquina, quizá baste con el turno. Recoger menos dato es la medida de protección más eficaz que existe, y la más barata.
3. **Fijar una política de retención.** El histórico llega a 2022. Conservar nombres indefinidamente sin una finalidad vigente contradice el principio de necesidad. Los pseudónimos pueden conservarse sin límite; los nombres, no.

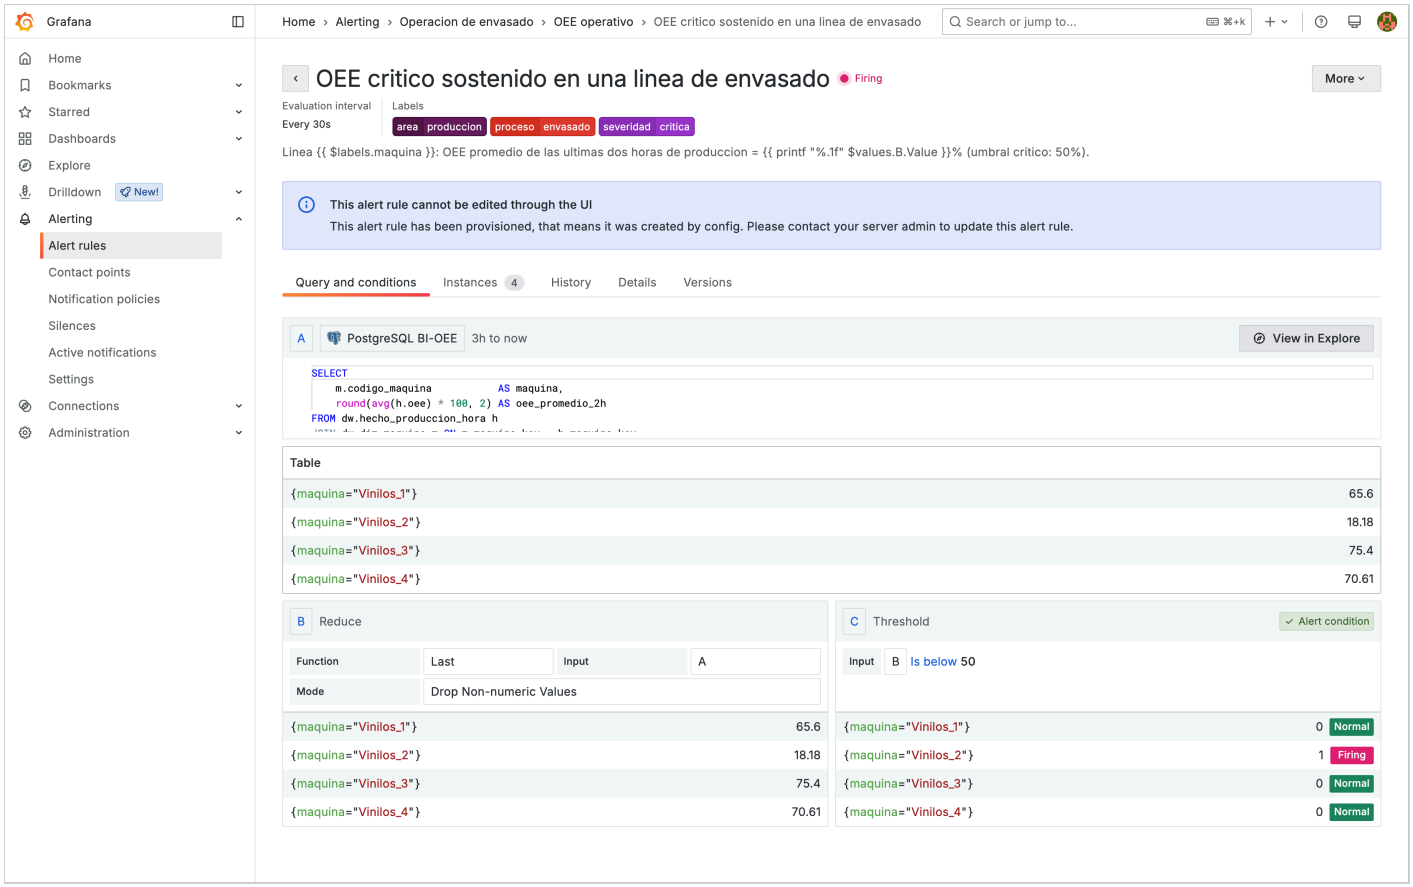
11 Capturas de los tableros



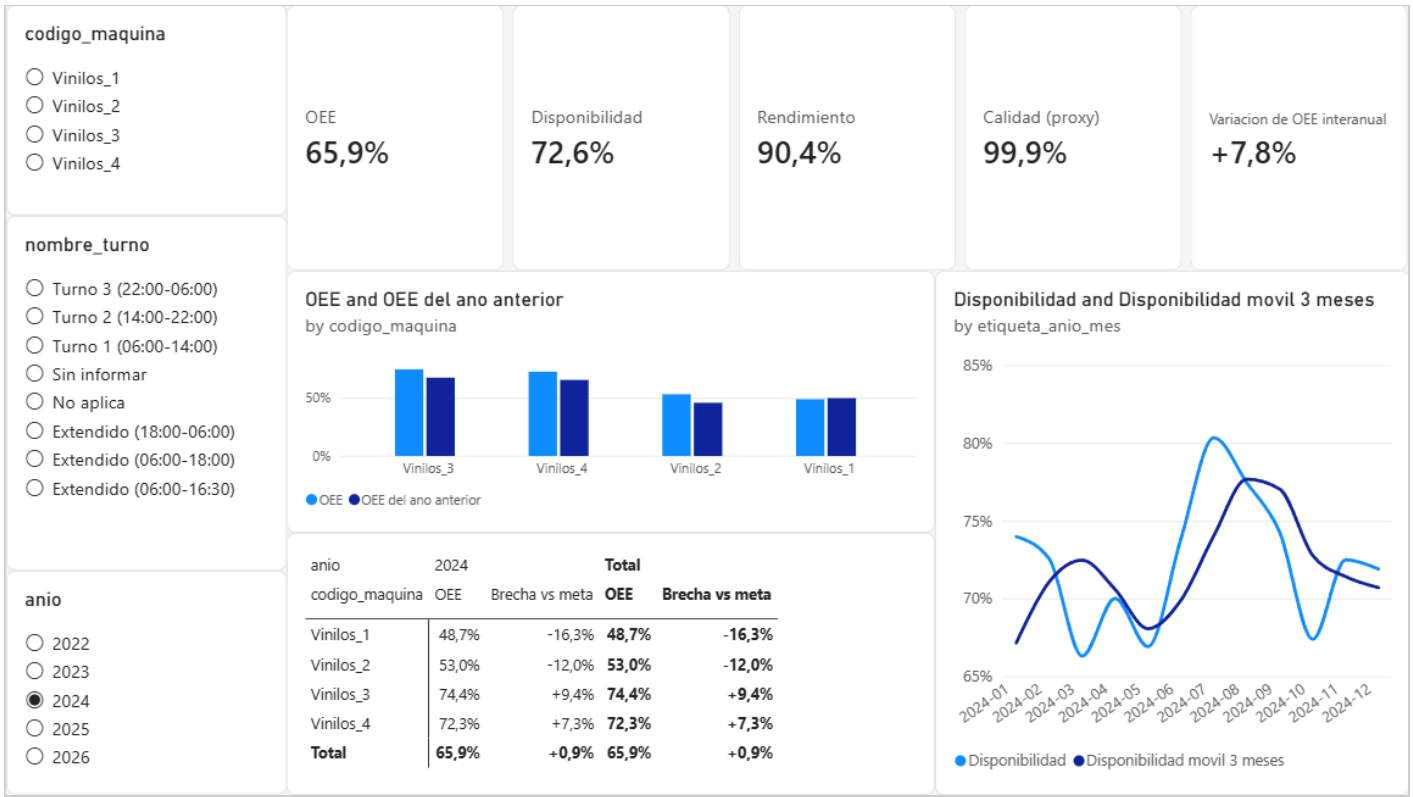
Grafana · tablero operativo completo



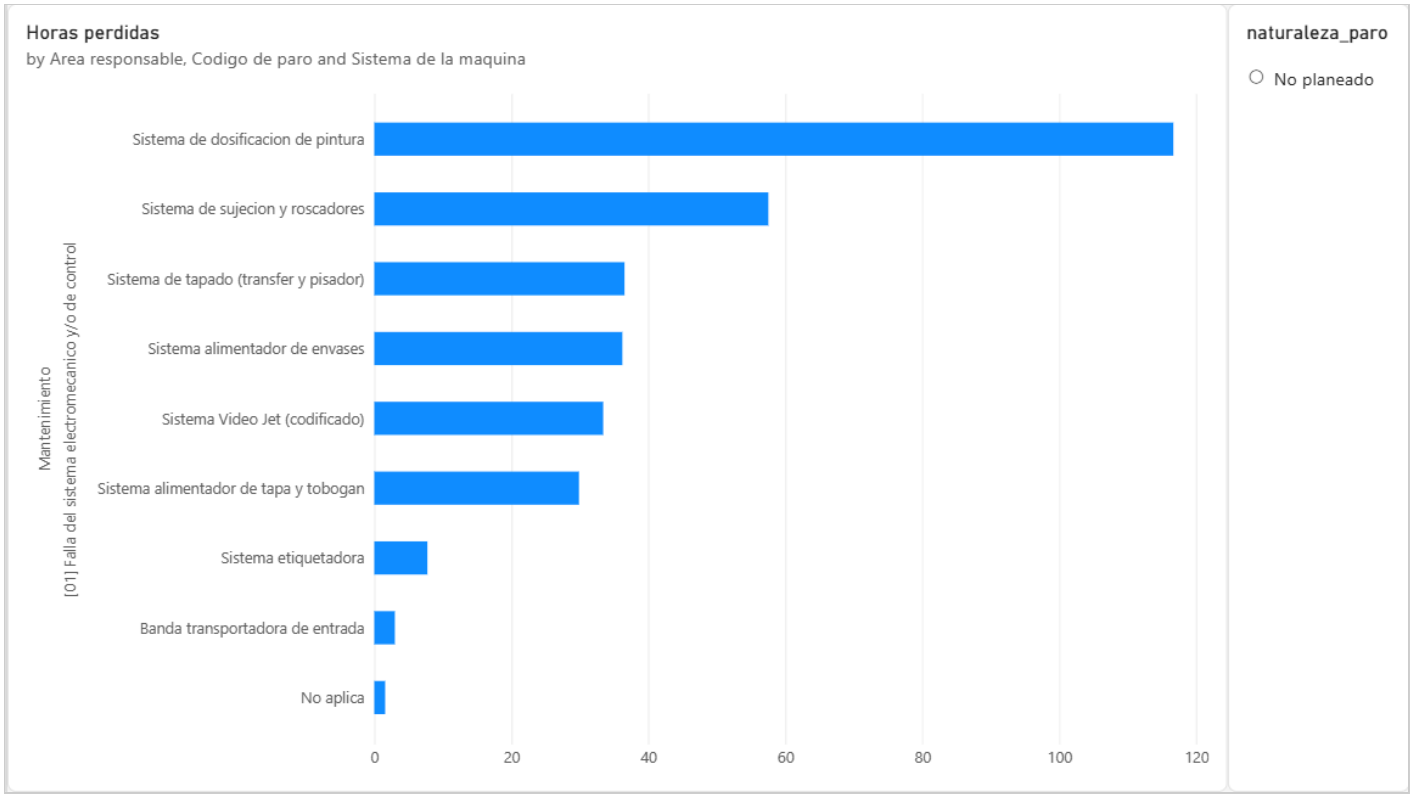
Grafana · estado actual por máquina



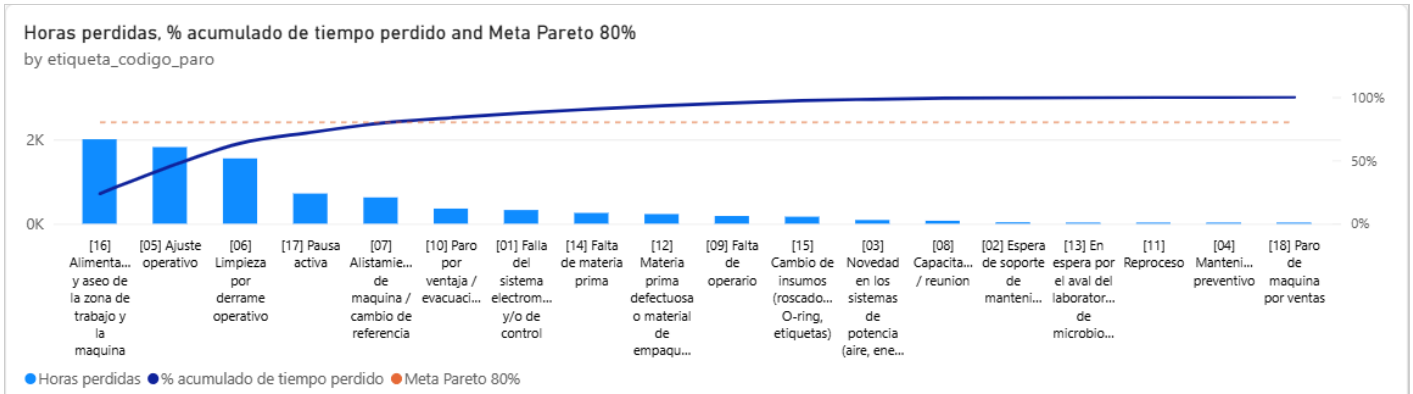
Grafana · alerta de OEE crítico disparada



Power BI · resumen gerencial

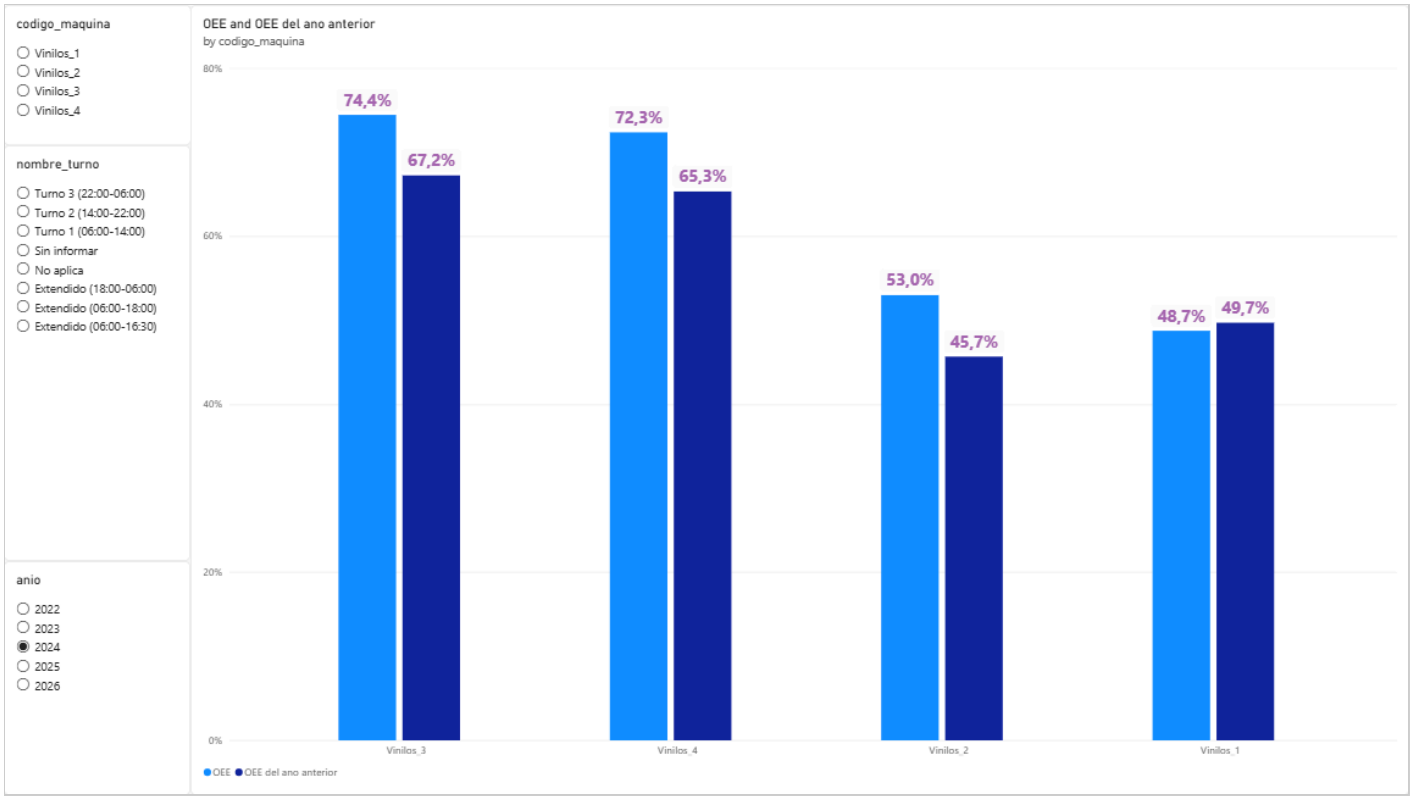


Power BI · drill-down de la jerarquía de paros



etiqueta_codigo_paro	Horas perdidas	Numero de eventos	Duracion media del paro	Unidades no producidas	% acumulado de tiempo perdido	Clasificacion Pareto
[16] Alimentacion y aseo de la zona de trabajo y la maquina	2.000,2	2.971	0,67	7.811.199	23,7%	Causa vital
[05] Ajuste operativo	1.813,7	3.076	0,59	5.728.666	45,2%	Causa vital
[06] Limpieza por derrame operativo	1.545,8	1.896	0,82	5.303.625	63,6%	Causa vital
[17] Pausa activa	713,2	4.346	0,16	623.849	72,0%	Causa vital
[07] Alistamiento de maquina / cambio de referencia	620,8	847	0,73	2.231.453	79,4%	Causa vital
[10] Paro por ventaja / evacuacion	356,4	536	0,66	704.623	83,6%	Causa trivial
[01] Falla del sistema electromecanico y/o de control	322,6	464	0,70	378.294	87,4%	Causa trivial
[14] Falta de materia prima	253,5	176	1,44	630.362	90,4%	Causa trivial
[12] Materia prima defectuosa o material de empaque no conforme	226,7	788	0,29	755.416	93,1%	Causa trivial
[09] Falta de operario	181,8	274	0,66	619.337	95,3%	Causa trivial
Total	**8.431,5**	**16.482**	**0,51**	**25.669.379**		**Causa vital**

Power BI · Pareto de causas de paro



Power BI · comparativo interanual